

Санкт–Петербургский государственный университет

ДРУЖИНИН Максим Александрович

Выпускная квалификационная работа

***Каскад моделей для оценки качества аудио-визуального
образовательного контента и создания рекомендаций по
его улучшению***

Уровень образования: бакалавриат

Направление 02.03.01 «Математика и компьютерные науки»

Основная образовательная программа СВ.5189.2022 «Науки о данных»

Научный руководитель:

научный сотрудник, Лаборатория искусственного
интеллекта, математики и компьютерных наук им.

А. А. Маркова,

к.ф.-м.н. Николаев Максим Сергеевич

Рецензент:

доцент, Национальный исследовательский ядер-
ный университет «МИФИ»,

к.ф.-м.н. Кирова Валерия Орлановна

Санкт-Петербург

2026 г.

Содержание

Введение	3
Глава 1. Анализ предметной области и обзор существующих подходов	5
1.1. Особенности образовательного видео как объекта оценки . .	5
1.2. Существующие инструменты и их ограничения	6
1.3. Методы оценки технического аудио-визуального качества . .	8
1.4. Анализ содержания и тематическая сегментация	9
1.5. Управление вниманием и восприятие учебного контента . . .	9
1.6. Выводы	11
Глава 2. Архитектура системы	12
2.1. Общая схема пайплайна	12
2.2. Контекст пользователя	13
2.3. Состав аналитической выдачи	13
Глава 3. Методология	15
3.1. Транскрипция и техническое качество аудио	15
3.1.1 Транскрипция	15
3.1.2 Техническое качество аудио	15
3.2. Техническое качество видео	16
3.3. Флаги восприятия	17
3.3.1 Флаг «Аудио Дисбаланс» (Логик)	18
3.3.2 Флаг «Смысловая унылость» (Интуит)	19
3.3.3 Флаг «Эмоциональный дисбаланс» (Эмоция)	20
3.3.4 Флаг «Визуальный шум» (Сенсорик)	20
3.4. Профиль подачи	21
3.5. Нарративная суммаризация	22
3.6. Метрика соответствия запросу	23
3.7. Пользовательский интерфейс	23
Заключение	25
Список литературы	26

Введение

Объём образовательного видеоконтента на открытых платформах растёт быстрее, чем появляются инструменты для его оценки. Пользователь, выбирая между десятками лекций по одной теме, вынужден ориентироваться на лайки, просмотры и удержание, то есть метрики, разработанные для развлекательного контента и оптимизированные под клик, а не под передачу знаний. Создатель, в свою очередь, не получает содержательной обратной связи: что именно в его лекции не работает и для кого.

Ситуация воспроизводит логику «рынка лимонов» [1]: обе стороны действуют в условиях информационной асимметрии. Устойчивых сигналов, позволяющих сопоставить видео с образовательными целями конкретной аудитории, не существует.

Образовательное видео как объект оценки принципиально отличается от развлекательного: длинный таймлайн, высокая смысловая нагрузка, мультимодальность (речь, слайды, жесты), неравномерность интерактивности и критическая зависимость от контекста целевой аудитории. Ни одна из классических платформенных метрик эти характеристики не учитывает.

Существующие инструменты решают смежные задачи: Gemini позволяет суммаризовать видео по ссылке и генерировать таймкоды, StudyFetch — формировать конспекты и флеш-карты. Однако ни один из них не оценивает видео относительно конкретного пользовательского запроса и не даёт интерпретируемой аналитики для принятия решений.

В данной работе предлагается система автоматизированной оценки образовательного видеоконтента, формирующая аналитическую выдачу в зависимости от профиля пользователя: его роли, уровня подготовки, погружённости в тему и цели просмотра. Система оценивает видео по двум осям — форма и содержание, и включает: техническое качество аудио и видео, систему бинарных флагов восприятия на основе типологии Юнга, профиль подачи (академичность и инструментальность), адаптивную нарративную суммаризацию с тематической сегментацией и метрику соответствия запросу. Все оценки формируются без эталонного референса — исключительно на основе анализа самого видео.

Цель работы — разработать инструмент автоматизированной оценки ка-

чества и релевантности образовательного видеоконтента, формирующий интерпретируемую аналитику для обучающихся и авторов контента.

Задачи:

1. Провести обзор существующих подходов к оценке качества аудио-визуального контента и выявить их ограничения применительно к образовательному видео.
2. Разработать структуру каскадного анализа, охватывающего технические, поведенческие и содержательные аспекты.
3. Реализовать модули оценки: технического качества, флагов восприятия, профиля подачи, нарративной суммаризации и метрики соответствия запросу.
4. Разработать пользовательский интерфейс, обеспечивающий интерпретируемое представление результатов анализа.

Глава 1. Анализ предметной области и обзор существующих подходов

1.1 Особенности образовательного видео как объекта оценки

Образовательное видео отличается от развлекательного по ряду характеристик, принципиальных для задачи оценки. Во-первых, средняя продолжительность лекционного контента на порядок превышает длину развлекательного ролика, что усложняет анализ и делает глобальные агрегированные оценки малоинформативными. Во-вторых, контент мультимодален: речь лектора, слайды, жесты и мимика несут смысловую нагрузку одновременно и по-разному влияют на восприятие в зависимости от аудитории. В-третьих, интерактивность распределена неравномерно — зрительская активность концентрируется в отдельных точках видео и не отражает качество остального материала. Наконец, релевантность образовательного видео не является универсальной характеристикой: одна и та же лекция может быть ценной для студента первого курса и бесполезной для практикующего специалиста. Оценка, не учитывающая контекст пользователя, принципиально неполна.

Из этих особенностей следует, что метрики, разработанные для оценки развлекательного контента (удержание, лайки, просмотры, CTR) не применимы к образовательному видео: они оптимизированы под другую цель и не несут содержательной информации о качестве подачи или релевантности материала.

Перечисленные особенности определяют структуру требований к системе оценки. Мультимодальность и длинный таймлайн означают, что оценка должна охватывать несколько каналов одновременно: деградация любого из них на протяжённом видео непосредственно влияет на восприятие. Неравномерность интерактивности и высокая смысловая плотность требуют анализа внутренней организации материала, а не только его поверхностных атрибутов. Из этого следует разбиение на два измерения: **форма** — как материал представлен технически и как лектор его подаёт, и **содержание** — что именно представлено и насколько это соответствует образовательным целям аудитории.

Форма охватывает техническое качество аудио- и видеоряда: чёткость звука, уровень шума, качество изображения, стабильность съёмки. Однако тех-

нического качества недостаточно: два видео с одинаковыми техническими характеристиками могут восприниматься принципиально по-разному в зависимости от стиля подачи лектора — тональности, эмоциональной окраски, характера жестикуляции, степени формальности. Эти элементы управляют вниманием обучающегося и определяют когнитивную нагрузку независимо от содержания. Вопрос о том, как именно формализовать и измерить паттерны подачи, рассматривается в разд. 1.5.

Содержание определяется структурой и логикой изложения: наличием вводных и заключительных элементов, последовательностью и связностью тем, соответствием названия реальному материалу, а также глубиной и актуальностью: уровнем сложности, плотностью материала, необходимыми пресреквизитами. Релевантность при этом не является изолированным свойством видео: она возникает на пересечении содержательных характеристик и профиля конкретного пользователя — его уровня подготовки, погружённости в тему и цели просмотра.

1.2 Существующие инструменты и их ограничения

Автоматическая оценка образовательного видеоконтента в существующих системах сводится преимущественно к двум категориям метрик: технические атрибуты (разрешение, частота кадров, уровень аудио) и тематическая классификация (тема, ключевые концепции, наличие нежелательного контента) [2]. Эти метрики используются платформами для помощи пользователям при выборе контента, однако не затрагивают ни качество подачи, ни педагогическую структуру. В академической литературе предпринимались попытки оценить более глубокие аспекты. Shi и др. [3] исследуют корреляции мультимодальных признаков (аудио, текстовых и визуальных) с субъективными оценками качества лекций на MOOC-платформе, устанавливая что просодические характеристики и кросс-модальные признаки значимо предсказывают воспринимаемое качество и прирост знаний. Pan и др. [4] предлагают мультимодальный классификатор, обученный предсказывать качество преподавания по пяти аспектам (Clarity, Empathy, Classroom Interaction, Technical Management и Time Management) на размеченных записях очных и вебинарных занятий, достигая точности 0.898 на

бинарной классификации. Zhu и др. [2] предлагает иную постановку: модель симулирует студента, «посещает» лекцию, затем сдаёт тест по внешним учебным материалам темы, и качество видео приравнивается к результату этого теста. Объединяет все три подхода базовая установка: задача формулируется как автоматическое вынесение вердикта о качестве видео. При этом VCEval требует внешних учебных материалов по каждой теме, что ограничивает применимость к произвольному контенту, а Shi и др. [3] и Pan и др. [4] требуют размеченных обучающих данных и плохо переносятся на новые домены и форматы подачи.

Gemini API позволяет взаимодействовать с YouTube-видео напрямую по ссылке и генерировать суммаризации и таймкоды [5]. Недавно анонсированный Ask YouTube расширяет эту функциональность в сторону поиска по личной истории просмотров [6, 7]. Оба инструмента позиционируются как средства работы с контентом в режиме диалога, а не как аналитические системы оценки. Стоимость инференса по YouTube URL через Gemini API может быть существенной при масштабной обработке: видео токенизируется примерно как 300 токенов в секунду, поэтому один час видео даёт около 1.08 млн входных токенов. В зависимости от модели это составляет примерно от \$0.11 за час видео на Gemini 2.5 Flash-Lite до \$2.70+ на Gemini 2.5 Pro, без учёта стоимости выходных токенов [8]. Это ограничивает применимость подхода при массовом анализе YouTube-видео.

Платформы аналогичные StudyFetch больше ориентированы на образование, но решают задачу усвоения уже выбранного материала: генерация конспектов, флеш-карт, тестов [9, 10]. Они включаются после выбора видео и не затрагивают вопрос о том, подходит ли это видео конкретному пользователю.

Поскольку ни один из перечисленных подходов не ставит задачу иначе: предоставить пользователю структурированную интерпретируемую аналитику по нескольким измерениям одновременно (форме, содержанию), чтобы он мог сам принять решение о соответствии видео своим целям. Ниже рассматриваются методологические основы для каждого из них: методы оценки технического качества аудио и видео (разд. 1.3), подходы к анализу содержания и тематической сегментации (разд. 1.4) и психологические функции как инструмент формализации паттернов восприятия (разд. 1.5).

1.3 Методы оценки технического аудио-визуального качества

Качество аудио. Методы оценки качества речевого аудио делятся на intrusive и non-intrusive. Intrusive-методы сравнивают сигнал с эталоном: классический пример — PESQ (Perceptual Evaluation of Speech Quality) [11], стандарт для оценки качества телефонной речи. Такие методы дают точные результаты в контролируемых условиях, но неприменимы к пользовательскому контенту, где эталонная запись отсутствует по определению.

Non-intrusive методы предсказывают воспринимаемое качество непосредственно из сигнала. Среди них выделяется класс перцептивных моделей, обученных имитировать субъективную оценку слушателя по шкале MOS (Mean Opinion Score). Одним из актуальных представителей является DNSMOS P.835 [12], предсказывающая три независимых компонента: качество речевого сигнала, уровень фонового шума и интегральное качество.

Для анализа просодики и характеристик голоса используются инструменты фонетического анализа — в частности, Praat [13], обеспечивающий точное извлечение фундаментальной частоты (F0) и интенсивности. Монотонность речи как характеристика подачи устойчиво коррелирует с низкой вариативностью F0 и громкости [3]. Для оценки эмоциональной окраски речи активно развиваются трансформерные модели [14], которые показывают, что предыдущие подходы систематически занижали точность по валентности, и предлагают архитектуру, закрывающую эту нишу.

Качество видео. No-reference оценка качества видео — активная область исследований, особенно применительно к пользовательскому контенту (UGC). Reference-based метрики, такие как Peak Signal-to-Noise Ratio (PSNR), Structural Similarity Index Measure (SSIM) [15] и VMAF [16] показывают высокую точность в задачах сжатия и стриминга, где оригинальный сигнал доступен, однако неприменимы к оценке снятого пользователем контента без эталона. VMAF, в частности, активно используется Netflix для контроля качества трансляций, но требует оригинального мастер-файла для сравнения.

Классические no-reference подходы, такие как BRISQUE [17], работают на уровне отдельных кадров и оценивают резкость и артефакты в пространствен-

ной области. Более современные модели, например DOVER [18], рассматривают видео целиком и разделяют техническую и эстетическую составляющие качества, что актуально для контента с неоднородными условиями съёмки.

Отдельный класс задач — анализ визуальной сцены и поведения спикера. Для детектирования и трекинга человека в кадре применяются фреймворки компьютерного зрения реального времени, среди которых MediaPipe [19] обеспечивает надёжное извлечение ключевых точек лица и позы. Обнаружение монтажных переходов решается через детекторы смены сцен [20]. Задача распознавания текста в кадре (на доске или слайдах) решается средствами OCR.

1.4 Анализ содержания и тематическая сегментация

Задача тематической сегментации (разбиение на связные смысловые блоки) длинного текста или транскрипта изучается давно. Классический подход TextTiling [21] основан на лексической когезии: границы тем определяются по падению лексического сходства между соседними окнами текста. Метод интерпретируем и не требует обучения, однако чувствителен к шуму в транскрипте и плохо справляется с плавными тематическими переходами, характерными для лекционного контента.

Нейросетевые подходы на основе эмбедингов улучшают качество сегментации за счёт семантического представления текста, но по-прежнему работают с транскриптом как единственным модальным каналом. LLM-based подходы — в частности, Chapter-Llama [22] — используют языковые модели для одновременной сегментации и именования глав, приближаясь по качеству к авторской разметке на видео с чёткой структурой.

1.5 Управление вниманием и восприятие учебного контента

Установив что стиль подачи влияет на восприятие независимо от содержания, необходимо ответить на методологический вопрос: как его структурировать для измерения? Просто перечислить жесты, тональность, темп речи и эмоциональную окраску недостаточно — неясно ни как их группировать, ни в какую сторону и насколько сильно мерить. Нужна теоретическая база, задающая осмысленную декомпозицию.

Теория когнитивной нагрузки [23] и принципы мультимедийного обучения [24] дают хорошо валидированную основу: как устроена рабочая память, как распределяются когнитивные ресурсы между каналами, какие принципы дизайна снижают экзаменационную нагрузку. Эти фреймворки описывают универсальные механизмы восприятия и остаются актуальными ориентирами в проектировании учебного контента. Однако они отвечают на вопрос «что работает для большинства», и не затрагивают вопрос о том, почему одно и то же видео с одинаковым уровнем сложности вызывает у разных людей принципиально разную реакцию на стиль подачи.

Направление когнитивных стилей Riding [25] и модели стилей обучения (VARK и другие) описывают предпочтительные режимы обработки информации: визуальный, аудиальный, вербальный. Интуиция привлекательная, но последующие исследования показали, что влияние стиля обучения на результат опосредовано множеством других факторов (содержанием, контекстом, мотивацией) и не воспроизводится как самостоятельный эффект [26]. Обучение оказывается слишком комплексным процессом чтобы объяснять его через единственную переменную предпочтений.

Наиболее разработанную теоретическую базу для описания индивидуальных различий в обработке информации предложил Юнг в «Психологических типах» [27]. Он выделил четыре психологические функции: мышление — обработка информации через логику и причинно-следственные связи; ощущение — через конкретный чувственный опыт и детали реальности; интуиция — через паттерны, абстракции и возможности; чувство — через ценности, отношения и личную значимость. Функции попарно противоположны (мышление–чувство, ощущение–интуиция), и у каждого человека одна-две являются доминирующими, определяя какой тип информации воспринимается наиболее естественно, а какой требует дополнительных когнитивных усилий.

Юнговская типология получила широкое практическое применение через адаптации: MBTI [28] стал наиболее массовым инструментом, используемым преимущественно в HR, и модель Big Five [29] с непрерывными чертами личности с высокой надёжностью при повторном тестировании и кросс-культурной воспроизводимостью. Критика типологических инструментов обоснована: по данным Pittenger [30], до 50% людей получают другой MBTI-тип при повторном

тестировании через пять недель. Важно, однако, что критика бьёт по инструменту классификации, а не по исходному юнговскому наблюдению о различиях в доминирующих функциях.

Для настоящей работы типологический инструментарий не применяется по прямому назначению: мы не определяем психологический тип зрителя. Четыре юнговские функции используются как теоретическая рамка для структурированной декомпозиции понятия «управление вниманием»: каждая функция описывает режим обработки информации, нарушение которого создаёт специфический тип когнитивного напряжения. Это позволяет перейти от бесструктурного перечня свойств подачи к осмысленной группировке детектируемых паттернов.

1.6 Выводы

Анализ существующих подходов показывает, что задача оценки образовательного видеоконтента не решается ни одним из них в отдельности. Методы оценки технического качества не учитывают содержание; инструменты анализа содержания не принимают во внимание пользовательский контекст; существующие платформы решают смежные задачи усвоения, а не выбора контента. Отдельную проблему представляет отсутствие интерпретируемости: большинство подходов выдают единый балл без декомпозиции и объяснения. Совокупность этих ограничений обосновывает необходимость каскадного мультимодального подхода с явным учётом профиля пользователя.

Глава 2. Архитектура системы

2.1 Общая схема пайплайна

В качестве базовой платформы выбран YouTube по двум причинам: это крупнейший агрегатор видеоконтента и образовательного контента в частности, охватывающий материалы от университетских курсов до авторских лекций на любом языке и по любой дисциплине; и для него существует развитая экосистема инструментов извлечения данных — в частности, yt-dlp [31], обеспечивающий доступ к аудио, видео, субтитрам и метаданным в рамках публичного API платформы. Архитектурно пайплайн не привязан к YouTube: замена источника данных требует адаптации только первого слоя сбора, тогда как все последующие модули работают с видеофайлом, аудиодорожкой и транскриптом — форматами, не специфичными для конкретной платформы. Это включает и локальные файлы при необходимости офлайн-обработки.

Система построена как четырёхслойный каскад, в котором каждый слой принимает результаты предыдущего и передаёт обогащённое представление следующему.

Слой 1 — сбор данных. На вход подаётся ссылка на YouTube-видео. Метаданные, аудиопоток и видеокадры извлекаются через yt-dlp и ffmpeg [32]; транскрипт — из субтитров YouTube либо через Whisper [33] при их отсутствии.

Слой 2 — извлечение признаков. Параллельно по трём каналам: из аудио извлекаются просодические и акустические характеристики; из видеокадров — метрики качества изображения, характеристики сцены и поведения спикера; из транскрипта — текстовые и семантические признаки.

Слой 3 — анализ. На основе извлечённых признаков вычисляются метрики и флаги: техническое качество, флаги восприятия, профиль подачи. На этом же слое выполняется LLM-анализ содержания. Результаты слоя 3 интерпретируются с учётом контекста пользователя.

Слой 4 — синтез и выдача. Формируется итоговая аналитическая выдача: таймкоды с нарративной суммаризацией, численные метрики, флаги и агрегированная метрика соответствия запросу.

2.2 Контекст пользователя

Система принимает четыре параметра пользовательского профиля:

- **Кто я (USER_TYPE)** — роль пользователя: обучающийся, автор контента, образовательная организация или заказчик контента.
- **Уровень образования (LEVEL)** — от школьника до специалиста / профессионала; для авторов контента — уровень целевой аудитории.
- **Уровень погружённости (IMMERSION_LEVEL)** — от «изучаю с нуля» до «экспертный уровень».
- **Цель просмотра (VIEW_GOAL)** — составить общее представление, закрыть точечные вопросы или последовательно изучить тему.

Выбор именно этих четырёх параметров продиктован стремлением к минимальному достаточному набору: вместе они покрывают ключевые сценарии использования и не требуют от пользователя избыточных усилий. Контекст пользователя пронизывает систему на нескольких уровнях: гранулярность тематической сегментации определяется целью просмотра; нарратив формируется не как универсальное описание видео, а как объяснение его ценности для конкретного профиля; интерпретация профиля подачи зависит от уровня и погружённости пользователя; метрика соответствия запросу агрегируется с учётом полного профиля. Для авторов контента состав выдачи расширяется: помимо содержательных таймкодов формируются таймкоды проблемных зон с привязкой к конкретным флагам.

2.3 Состав аналитической выдачи

Система формирует пять типов выходных данных:

- **Техническое качество** — агрегированная оценка аудио и видео по воспринимаемым характеристикам.
- **Флаги восприятия** — бинарные сигналы, фиксирующие наличие паттернов подачи, негативно влияющих на восприятие.

- **Профиль подачи** — положение видео на двух независимых осях: академичность и инструментальность.
- **Нарративная суммаризация** — тематические сегменты с таймкодами и текстовое описание ценности видео относительно запроса пользователя.
- **Метрика соответствия запросу** — интегральная оценка, агрегирующая все предыдущие компоненты с учётом пользовательского профиля.

Глава 3. Методология

3.1 Транскрипция и техническое качество аудио

3.1.1 Транскрипция

Транскрипт используется несколькими последующими модулями пайплайна, поэтому качество и формат транскрипции критичны для системы в целом. Ключевое требование — сегментация с точными временными метками: без неё невозможно вычислить WPM, выровнять текстовые признаки с аудио и корректно работать с временной осью.

YouTube предоставляет автоматические субтитры, однако они непригодны как источник транскрипта для последующей обработки: пунктуация слабая или отсутствует, что ломает любые NLP-модули downstream; имена, термины и аббревиатуры часто транскрибируются некорректно; структура данных не предоставляет надёжных сегментных границ. Whisper решает все три проблемы из коробки.

Вместо этого применяется faster-whisper с моделью large-v3-turbo — дистиллированной версией large-v3, обеспечивающей сопоставимое качество при значительно меньшем времени инференса. Whisper стабильно работает на лекционном аудио, даёт точные временные метки на уровне сегментов и не зависит от того, загружал ли автор субтитры на платформу.

3.1.2 Техническое качество аудио

Оценка качества аудио строится на двух уровнях: перцептивном и техническом.

На перцептивном уровне применяется DNSMOS P.835. Из рассмотренных non-intrusive подходов DNSMOS выбрана по двум причинам. Во-первых, в отличие от ViSQOL [34] и большинства MOS-предикторов, она декомпозирует оценку на три независимых компонента — качество речевого сигнала (SIG), уровень фонового шума (BAK) и интегральное качество (OVR) — что позволяет локализовать источник деградации: низкий BAK указывает на шум окружения, низкий SIG — на проблемы с голосом. Единый балл эту информацию теряет. Во-вторых, модель обучена специфически на речи, а не на общем

аудио, что делает её более надёжной на лекционном материале с фоновым шумом аудитории, эхом и реверберацией. Модель принимает моно WAV 16kHz — конвертация выполняется через ffmpeg на входе пайплайна.

На техническом уровне SNR вычисляется через silero-VAD [35]: VAD-модель делит аудио на речевые сегменты и паузы, SNR считается как отношение RMS речи к RMS шума в паузах. Этот подход не требует отдельной модели шумоподавления и даёт стабильные результаты на лекционном аудио. Громкость оценивается через LUFS (pyloudnorm) — стандартная перцептивная метрика для вещательного контента.

Клиппинг детектируется тремя независимыми метриками: clipping_ratio, crest_factor и spectral_flatness. Crest factor — отношение пика к RMS сигнала: у клипированного аудио пики срезаны, поэтому crest factor аномально низкий даже после нормализации амплитуды. Spectral flatness фиксирует выравнивание спектра, характерное для клиппирования. Тройная проверка необходима потому что YouTube нормализует амплитуду при загрузке видео — прямой порог по амплитуде после этой нормализации ненадёжен. Crest factor и spectral_flatness работают и после нормализации, поскольку клиппинг меняет форму сигнала, а не только его уровень.

3.2 Техническое качество видео

Видео скачивается через yt-dlp в максимально доступном разрешении до 1080p. Кадры извлекаются с частотой 0.1 fps (один кадр каждые 10 секунд) — этого достаточно для оценки устойчивых характеристик качества и существенно снижает вычислительную нагрузку по сравнению с полным перебором кадров.

На перцептивном уровне применяется DOVER [18] — из доступных по-reference моделей она единственная разделяет техническую и эстетическую составляющие качества и обучена именно на UGC-видео, что соответствует характеру лекционного контента. Reference-based альтернативы (VMAF и др.) требуют оригинального мастер-файла и неприменимы. BRISQUE [17] дополняет DOVER на уровне отдельных кадров: его стандартное отклонение по кадрам используется как метрика временной консистентности — резкие выбросы сиг-

нализируют о нестабильных условиях съёмки.

Стабильность видеоряда оценивается через `vidstabdetect`: модуль измеряет векторы движения между кадрами и даёт количественную оценку тряски. Это важная самостоятельная характеристика, не улавливаемая DOVER.

Два оставшихся компонента специфичны для образовательного формата и не являются метриками качества для видео в общем случае. Присутствие лектора в кадре отслеживается через MediaPipe [19]: лекционный формат предполагает визуальный контакт со спикером — его невербальная коммуникация, жесты и мимика несут смысловую нагрузку. Отсутствие лица в кадре или его малый размер — деградация качества именно для образовательного видео. Читаемость доски и слайдов оценивается через EasyOCR [36]: в лекции визуальный ряд является частью содержания, а не фоном, поэтому засветка проектора или нечитаемый текст — прямые потери информации, которые для развлекательного видео не имели бы значения.

3.3 Флаги восприятия

Флаги восприятия — бинарные сигналы, фиксирующие паттерны подачи, которые негативно влияют на восприятие у конкретного типа аудитории. Каждый флаг соответствует одному из четырёх типов типологии Юнга [27] и детектирует нарушение его доминирующего канала восприятия. Флаги не взаимоисключающие — несколько могут сработать одновременно.

Концепция флагов возникла из наблюдения, что одни и те же проблемы подачи систематически повторяются и по-разному влияют на разных зрителей. Перенос типологии на задачу детектирования был откалиброван через опрос 52 человек из образовательной среды, знакомых со своим типом. Участники верифицировали соответствие между паттернами подачи и тем, что реально мешает восприятию для каждого типа.

Часть паттернов требует понимания смысла — наличие образности, характер промежуточных итогов, соответствие эмоционального тона контексту. Классические NLP-методы здесь недостаточны: нужна семантика процесса, а не поверхностные признаки текста. Для таких задач применяется LLM в формате бинарных вопросов с примерами из текста — примеры делают ответы верифи-

цируемыми. Для LLM-анализа во всех флагах (и далее) используется DeepSeek V4 [37] — модель выбрана за сильные reasoning-способности, надёжную работу с русскоязычным текстом и стоимость инференса, не сопоставимую с моделями сравнимого качества. LLM-вызовы флагов встроены в существующий нарративный модуль (о котором будет дальше) и не создают дополнительных расходов на контекст.

Для задач с нативным аудио- и визуальным входом применяется семейство Qwen. Выбор обусловлен тем, что моделей с нативной обработкой аудио и видео напрямую — без промежуточной транскрипции или извлечения признаков — на открытом рынке крайне мало, а доступных по стоимости и воспроизводимых локально ещё меньше. Семейство Qwen закрывает обе задачи: Qwen-Omni [38] обрабатывает аудиопоток напрямую, Qwen3-VL [39] — видеокadres. Дополнительным преимуществом является наличие компактных открытых версий для локального тестирования с последующим переходом на API-версии для production. Тестирование визуального модуля проводилось на Qwen3-VL-8B локально — модель показала достаточное качество на задаче оценки визуальной опрятности, после получения API принято решение перейти на Qwen3-VL-Plus: это освобождает локальный compute для других модулей и даёт прирост точности без изменения логики. Аудиоветка семейства (Qwen2.5-Omni-7B локально и Qwen2.5-Omni-Plus через API) тестировалась для задачи детектирования артикуляционных дефектов речи — результаты и причины неудачи описаны в разделе флага Аудио дисбаланс.

3.3.1 Флаг «Аудио Дисбаланс» (Логик)

Логический тип воспринимает информацию преимущественно через аудиальный канал — звук является его основным каналом потребления контента. Флаг срабатывает когда речь или звук мешает восприятию: фоновые шумы, тембральные особенности, слова-паразиты и просторечия.

Технические метрики (DNSMOS ovrl/sig/bak, SNR, клиппинг, LUFs) переиспользуются из модуля 4.1 без повторного расчёта — они напрямую покрывают то, что раздражает логика. Слова-паразиты, просторечия и орфоэпические ошибки детектируются LLM на транскрипте в формате бинарных вопросов с

примерами из текста — словарный подход не используется, поскольку пропускает нестандартные паразиты и региональные просторечия.

Отдельно исследовалась задача детектирования артикуляционных дефектов речи (картавость, нестандартный тембр) — логики тратят значительно больше когнитивных ресурсов на восприятие нестандартного звукоряда. Были последовательно проверены три подхода. Whisper avg_logprob: гипотеза состояла в том, что модель будет менее уверена при транскрипции дефектной речи — тесты опровергли это, нормальные видео нередко давали более низкий logprob из-за сложности терминологии, а не качества произношения. Praat jitter/shimmer/HNR: клинические нормы рассчитаны на студийные записи изолированных гласных — на YouTube-аудио с естественной речью все лекторы, включая тех с очевидными дефектами, попадали в «патологическую» зону без какого-либо разделения. Qwen Omni (тестировались Qwen2.5-Omni-7B локально и Qwen2.5-Omni-Plus через API): аудио LLM обучены на выравнивании контента, а не паралингвистических характеристиках — модели возвращали false на видео с очевидными дефектами. Корневая проблема: не существует датасета с текстовыми описаниями дефектов речи, на котором можно было бы обучить или настроить модель. Детектирование дефектов речи исключено из текущей реализации как нерешённая подзадача.

3.3.2 Флаг «Смысловая унылость» (Интуит)

Интуитивный тип воспринимает информацию через идеи, паттерны и концепции — ему важна смысловая динамика и образность изложения. Флаг срабатывает когда лекция семантически бедна: нет крючка в начале, нет метафор и аналогий, промежуточные итоги дублируют сказанное вместо синтеза, лектор читает слайды дословно.

Основной инструмент — LLM-анализ транскрипта: модель отвечает на серию бинарных вопросов с примерами из текста (наличие hook в первые минуты, использование метафор, характер промежуточных итогов, авторская позиция). Формат с примерами позволяет верифицировать ответы и снизить риск галлюцинаций. Этот LLM-вызов встроен в существующий нарративный модуль и не создаёт дополнительных расходов на контекст.

Дублирование слайдов детектируется отдельно. Сначала YOLOE [40] определяет наличие доски или экрана в кадре — запускать OCR на каждом кадре без проверки наличия текстовой поверхности расточительно, YOLOE как open-vocabulary детектор справляется с этой задачей без дообучения под конкретный тип сцены. Текст извлекается через EasyOCR — он выбран за нативную поддержку кириллицы при приемлемом качестве: лекционный материал часто смешивает русский и английский, Tesseract на таком материале даёт существенно хуже результаты. Далее семантическая близость между речью лектора и текстом слайда измеряется NLP-методами — высокое сходство сигнализирует о дублировании.

3.3.3 Флаг «Эмоциональный дисбаланс» (Эмоция)

Эмоциональный тип воспринимает через атмосферу и отношения — ему важна живость и уместность эмоционального тона. Флаг срабатывает в двух противоположных случаях: лектор читает механически без эмоциональной окраски, либо эмоциональный напор не соответствует контексту.

Эмоциональная окраска речи оценивается через модель audEERING [14] — трансформерную SER-архитектуру, специально разработанную для закрытия valence gap: предыдущие поколения SER-моделей стабильно предсказывали arousal, но систематически ошибались по валентности (позитивность / негативность эмоции). Модель применяется по скользящим окнам на аудиосегментах — вычисляется распределение эмоциональных состояний и их вариативность во времени. Именно вариативность является ключевым признаком: флаг детектирует не конкретную эмоцию, а её отсутствие или избыток относительно контекста. Модель обучена на английских данных, однако просодические паттерны эмоциональной речи переносятся между языками устойчиво, что подтверждается в том числе авторами работы.

3.3.4 Флаг «Визуальный шум» (Сенсорик)

Сенсорный тип воспринимает через визуальный канал и реальность происходящего в кадре. Флаг срабатывает когда визуальный ряд перегружен раздражителями: резкие склейки с большим изменением картинки между ними,

хаотичное движение в сцене, перегруженность кадра.

Монтажные склейки детектируются через PySceneDetect [20] — лёгкий инструмент без зависимостей от нейросетевых моделей, работающий напрямую на видеопотоке. Резкость перехода оценивается через OpenCV и MediaPipe: позиция лица лектора сравнивается между кадрами до и после склейки — резкое смещение спикера в кадре является маркером дезориентирующего монтажа.

Общая визуальная опрятность и перегруженность сцены требует семантического понимания картинки и не поддаётся надёжной формализации через классические дескрипторы — яркость, контраст и оптический поток не улавливают смысловую перегруженность кадра. Для этой задачи применяется Qwen3-VL. Тестирование проводилось локально на Qwen3-VL-8B — модель показала достаточное качество на задаче оценки визуальной опрятности при разумном потреблении памяти. После получения доступа к API принято решение перейти на Qwen3-VL-Plus: это освобождает локальный compute для других модулей пайплайна и даёт прирост точности без изменения логики модуля.

3.4 Профиль подачи

Профиль подачи описывает глобальную педагогическую ориентацию лекции по двум независимым осям: академичность и инструментальность. Важно, что это не про поверхностные признаки текста — наличие формул, определений или примеров, а скорее про глобальную цель занятия. Лекция по линейной алгебре на, условном, экономфаке и на матфаке могут иметь близкий лексический состав, иметь теоремы и аксиомы, но принципиально разную педагогическую ориентацию — одна объясняет чтобы применять, другая строит строгую теорию.

Рассмотренные подходы. Первым был протестирован zero-shot NLI: академичность и инструментальность формулировались как гипотезы, модель возвращала вероятности entailment. Результатом является полная сатурация: все видео получили 9.5–10.0 по обеим осям. NLI-модели обучены на формальном entailment общего характера и не различают педагогические ориентации внутри образовательного дискурса — они фиксируют формальное наличие признаков («в тексте есть определения» значит true), а не глобальную цель занятия.

Следующая попытка — LLM с непрерывной шкалой 0–1. Та же проблема

в другом виде: без якорных точек модель не имеет опоры для дифференциации, оценки кластеризовались в узкой зоне.

Выбранный подход. Дискретная пятибалльная шкала с якорными описаниями для каждого уровня. Академичность: от 1 («разговорное объяснение на пальцах без формальных определений») до 5 («аксиоматическое построение предмета, доказательства, строгая структура понятий»). Инструментальность: от 1 («объяснение без применения — обсуждает, мотивирует, но не учит действовать») до 5 («tutorial: пошаговые процедуры, вычисления, код, результат который можно воспроизвести»). Внутри каждого уровня модель дополнительно выставляет score 0.0–1.0 как точную позицию это даёт непрерывность при сохранении категориальной структуры.

Оси независимы, так как семинар высокого уровня с теорией и задачами может получить 5 по академичности и 4 по инструментальности одновременно. Модель предоставляет evidence (конкретные цитаты и наблюдения из транскрипта) для каждой оценки для валидации. Используется LLM с включённым thinking — reasoning-лог показывает что модель действительно анализирует педагогическую структуру, а не просто сопоставляет паттерны.

3.5 Нарративная суммаризация

Нарративный модуль формирует текстовую часть выдачи это компонент системы, который читается как связный текст, а не набор метрик, и состоит из трёх компонентов: тематической сегментации с таймкодами, педагогического анализа и собственно нарратива.

Тематическая сегментация. Транскрипт разбивается на смысловые блоки с таймкодами и названиями тем. Гранулярность адаптируется под цель просмотра: пользователь с целью «составить общее представление» получает укрупненные блоки, пользователь с целью «последовательно изучить тему» — детальную разбивку с таймкодами каждого подраздела.

Педагогический анализ. LLM оценивает структурные характеристики лекции относительно заявленной темы и пользовательского профиля: пресреквизиты (что нужно знать чтобы смотреть), пробелы в теме (что заявлено в названии но не раскрыто), плотность материала, соответствие названия содер-

жанию.

Нарратив. Неожиданно наиболее нетривиальный компонент. Задача формулируется так: текст от лица человека, который посмотрел видео и понял в чём его ценность это именно не пересказ тем, а объяснение что именно примечательно в этом видео для конкретного пользователя с его профилем. Пересказ («лектор объясняет пределы функций») не помогает принять решение о просмотре, нарратив («для бакалавра первого курса который хочет разобраться с нуля — редкий пример где строгость не жертвуется ради доступности») — помогает.

В ходе разработки было установлено что качество нарратива зависит от модели и режима инференса. Тестировались несколько конфигураций: модели без thinking давали формальные пересказы структуры вместо оценки ценности, модели с thinking но без достаточного reasoning-бюджета давали поверхностный анализ. Итоговая конфигурация использует LLM с включённым thinking и достаточным бюджетом токенов на рассуждение — reasoning-лог показывает, что модель отмечает редкие педагогические приёмы, конкретные понятия, выделяет что отличает видео от аналогичных.

3.6 Метрика соответствия запросу

Метрика соответствия запросу — интегральная оценка по шкале 0–100, агрегирующая все вычисленные компоненты с учётом пользовательского профиля. Одно и то же видео получает разный балл для школьника и специалиста, для цели «составить общее представление» и «последовательно изучить тему». Дополнительно учитываются метаданные: соответствие названия содержанию и наличие у канала связанной серии лекций.

Методология взвешивания компонентов находится в разработке: текущие веса подобраны эмпирически на валидационном датасете и требуют дальнейшей калибровки.

3.7 Пользовательский интерфейс

Интерфейс решает две задачи: минимизировать усилия пользователя на входе и сделать выдачу интерпретируемой без дополнительного контекста.

Выбор четырёх входных параметров был нетривиальным упражнением: хотелось покрыть ключевые сценарии использования при минимальном количестве полей. Итоговый набор — роль, уровень образования, погружённость в тему, цель просмотра — признан минимально достаточным после нескольких итераций.

Поскольку пайплайн рисерческий и занимает несколько минут, пользователю отображаются этапы обработки в реальном времени, включая появление транскрипта по мере его готовности. Важно для ресурсоёмкого процесса, чтобы пользователь понимал что происходит.

На экране результатов пользовательские параметры остаются видны постоянно, а всё остальное интерпретируется относительно них. Метрики интерактивны: при нажатии раскрывается описание и интерпретация применительно к конкретному видео. Флаги реализованы как бинарные индикаторы — числовые шкалы для них не используются, поскольку создавали бы ложное ощущение точности. Профиль подачи визуализирован как спидометр со смещением от центра, что передаёт доминирующую ориентацию нагляднее двух отдельных чисел. Таймкоды в нарративной части кликабельны и переключают встроенный YouTube-плеер на нужный момент.

Заключение

В рамках работы разработана система автоматизированной оценки образовательного видеоконтента, формирующая аналитическую выдачу в зависимости от профиля пользователя. Реализованы следующие модули: техническое качество аудио и видео, четыре флага восприятия на основе типологии Юнга, профиль подачи по осям академичности и инструментальности, нарративная суммаризация с адаптивной тематической сегментацией и метрика соответствия запросу. Разработан пользовательский интерфейс с интерактивной аналитической выдачей.

Система построена как no-reference пайплайн — все оценки формируются без эталонного референса и не зависят от платформенных метрик. Контекстная зависимость выдачи от пользовательского профиля реализована на уровне гранулярности сегментации, весов метрик и интерпретации результатов.

Для демонстрации необходимо разработать сценарный анализ на реальных видео, демонстрирующий срабатывание каждого модуля в различных условиях подачи и для разных пользовательских профилей.

Список литературы

- [1] George A. Akerlof. «The Market for “Lemons”: Quality Uncertainty and the Market Mechanism». В: *Quarterly Journal of Economics* 84.3 (1970), с. 488—500. DOI: 10.2307/1879431. URL: <https://doi.org/10.2307/1879431>.
- [2] Xiaoxuan Zhu и др. «VCEval: Rethinking What is a Good Educational Video and How to Automatically Evaluate It». В: (2025). arXiv: 2407.12005. URL: <https://arxiv.org/abs/2407.12005>.
- [3] Jing Shi и др. «Investigating Correlations of Automatically Extracted Multimodal Features and Lecture Video Quality». В: *Proceedings of the 1st International Workshop on Search as Learning with Multimedia Information (SALMM '19)*. ACM, 2019, с. 11—19. DOI: 10.1145/3347451.3356731. URL: <https://doi.org/10.1145/3347451.3356731>.
- [4] Yueran Pan и др. «A Multimodal Framework for Automated Teaching Quality Assessment of One-to-many Online Instruction Videos». В: *Proceedings of the 26th International Conference on Pattern Recognition (ICPR)*. IEEE, 2022, с. 1777—1783. URL: <https://ieeexplore.ieee.org/document/9956185>.
- [5] Google Developers. *Building with Gemini 2.0: Video Understanding*. 2024. URL: <https://www.youtube.com/watch?v=Mot-JEU26GQ> (дата обр. 23.05.2026).
- [6] Jay Peters. *Google is Testing AI Chatbot Search for YouTube*. 2026. URL: <https://www.theverge.com/streaming/919441/google-ask-youtube-ai-chatbot-search> (дата обр. 23.05.2026).
- [7] The Keyword. *YouTube Tests “Ask YouTube” AI Search Experience*. 2026. URL: <https://www.thekeyword.co/news/ask-youtube-ai-search> (дата обр. 23.05.2026).
- [8] Google Developers. *Video Understanding*. 2026. URL: <https://ai.google.dev/gemini-api/docs/interactions/video-understanding> (дата обр. 23.05.2026).

- [9] StudyFetch. *StudyFetch Documentation: Your Complete Guide to Mastering StudyFetch's AI-Powered Learning Tools*. 2024. URL: <https://www.studyfetch.com/> (дата обр. 23.05.2026).
- [10] Laxu AI Editorial Team. *Laxu AI vs Quizlet vs Anki vs StudyFetch vs Knowt: Best Flashcard App in 2026?* 14 янв. 2026. URL: <https://laxuai.com/blog/laxu-ai-vs-quizlet-vs-anki-comparison> (дата обр. 23.05.2026).
- [11] ITU-T. *Perceptual Evaluation of Speech Quality (PESQ): An Objective Method for End-to-End Speech Quality Assessment of Narrow-Band Telephone Networks and Speech Codecs*. P.862. International Telecommunication Union. 2001. URL: <https://www.itu.int/rec/T-REC-P.862> (дата обр. 23.05.2026).
- [12] Chandan K. A. Reddy, Vishak Gopal и Ross Cutler. «DNSMOS P.835: A Non-Intrusive Perceptual Objective Speech Quality Metric to Evaluate Noise Suppressors». В: *2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2022, с. 886—890. DOI: 10.1109/ICASSP43922.2022.9746108. arXiv: 2110.01763. URL: <https://arxiv.org/abs/2110.01763>.
- [13] Paul Boersma. «Praat, a System for Doing Phonetics by Computer». В: *Glott International* 5.9/10 (2001), с. 341—345. URL: https://www.fon.hum.uva.nl/praat/manual/FAQ/_How_to_cite_Praat.html (дата обр. 23.05.2026).
- [14] Johannes Wagner и др. «Dawn of the Transformer Era in Speech Emotion Recognition: Closing the Valence Gap». В: (2022). arXiv: 2203.07378. URL: <https://arxiv.org/abs/2203.07378>.
- [15] Zhou Wang и др. «Image Quality Assessment: From Error Visibility to Structural Similarity». В: *IEEE Transactions on Image Processing* 13.4 (2004), с. 600—612. DOI: 10.1109/TIP.2003.819861.
- [16] Zhi Li и др. *Toward a Practical Perceptual Video Quality Metric*. 6 июня 2016. URL: <https://techblog.netflix.com/2016/06/toward-practical-perceptual-video.html> (дата обр. 23.05.2026).

- [17] Anish Mittal, Anush Krishna Moorthy и Alan Conrad Bovik. «No-Reference Image Quality Assessment in the Spatial Domain». В: *IEEE Transactions on Image Processing* 21.12 (2012), с. 4695—4708. DOI: 10.1109/TIP.2012.2214050. URL: <https://doi.org/10.1109/TIP.2012.2214050>.
- [18] Haoning Wu и др. «Exploring Video Quality Assessment on User Generated Contents from Aesthetic and Technical Perspectives». В: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023. arXiv: 2211.04894. URL: <https://arxiv.org/abs/2211.04894>.
- [19] Camillo Lugaresi и др. «MediaPipe: A Framework for Building Perception Pipelines». В: (2019). arXiv: 1906.08172. URL: <https://arxiv.org/abs/1906.08172>.
- [20] Brandon Castellano. *PySceneDetect: Python-Based Video Scene Cut/Transition Detection Program and Library*. 2020. URL: <https://github.com/BreakthroughPySceneDetect> (дата обр. 23.05.2026).
- [21] Marti A. Hearst. «TextTiling: Segmenting Text into Multi-Paragraph Subtopic Passages». В: *Computational Linguistics* 23.1 (1997), с. 33—64. URL: <https://aclanthology.org/J97-1003/> (дата обр. 23.05.2026).
- [22] Lucas Ventura и др. «Chapter-Llama: Efficient Chaptering in Hour-Long Videos with LLMs». В: (2025). arXiv: 2504.00072. URL: <https://arxiv.org/abs/2504.00072>.
- [23] John Sweller. «Cognitive Load During Problem Solving: Effects on Learning». В: *Cognitive Science* 12.2 (1988), с. 257—285. DOI: 10.1207/s15516709cog12024.
- [24] Richard E. Mayer. *Multimedia Learning*. 2-е изд. New York: Cambridge University Press, 2009.
- [25] Richard J. Riding. «On the Nature of Cognitive Style». В: *Educational Psychology* 17.1–2 (1997), с. 29—49. DOI: 10.1080/0144341970170102.
- [26] Harold Pashler и др. «Learning Styles: Concepts and Evidence». В: *Psychological Science in the Public Interest* 9.3 (2008), с. 105—119. DOI: 10.1111/j.1539-6053.2009.01038.x.

- [27] Carl Gustav Jung. *Psychologische Typen*. Russian translation: *Психологические типы*, 1995. Zürich: Rascher Verlag, 1921. URL: https://archive.org/details/Psychologische_Typen (дата обр. 23.05.2026).
- [28] Isabel Briggs Myers и др. *MBTI Manual: A Guide to the Development and Use of the Myers-Briggs Type Indicator*. 3-е изд. Palo Alto, CA: Consulting Psychologists Press, 1998. ISBN: 0891061304.
- [29] Paul T. Costa и Robert R. McCrae. *Revised NEO Personality Inventory (NEO-PI-R) and NEO Five-Factor Inventory (NEO-FFI) Professional Manual*. Odessa, FL: Psychological Assessment Resources, 1992.
- [30] David J. Pittenger. «Measuring the MBTI... and Coming Up Short». В: *Journal of Career Planning and Employment* 54.1 (1993), с. 48—52.
- [31] yt-dlp contributors. *yt-dlp: A youtube-dl Fork with Additional Features and Fixes*. 2021. URL: <https://github.com/yt-dlp/yt-dlp> (дата обр. 23.05.2026).
- [32] FFmpeg Developers. *FFmpeg*. 2026. URL: <https://ffmpeg.org/> (дата обр. 23.05.2026).
- [33] Alec Radford и др. «Robust Speech Recognition via Large-Scale Weak Supervision» В: (2022). arXiv: 2212.04356. URL: <https://arxiv.org/abs/2212.04356>.
- [34] Michael Chinen и др. «ViSQOL v3: An Open Source Production Ready Objective Speech and Audio Metric». В: *2020 Twelfth International Conference on Quality of Multimedia Experience (QoMEX)*. IEEE, 2020, с. 1—6. DOI: 10.1109/QoMEX48832.2020.9123150. arXiv: 2004.09584. URL: <https://arxiv.org/abs/2004.09584>.
- [35] Silero Team. *Silero VAD: Pre-Trained Enterprise-Grade Voice Activity Detector*. 2021. URL: <https://github.com/snakers4/silero-vad> (дата обр. 23.05.2026).
- [36] JaidevAI. *EasyOCR: Ready-to-Use Optical Character Recognition (OCR) Toolkit*. 2020. URL: <https://github.com/JaidevAI/EasyOCR> (дата обр. 23.05.2026).

- [37] DeepSeek-AI. *DeepSeek-V4: Towards Highly Efficient Million-Token Context Intelligence*. Тех. отч. DeepSeek-AI, 2026. URL: <https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro> (дата обр. 23.05.2026).
- [38] Qwen Team. «Qwen3.5-Omni Technical Report». B: (2026). arXiv: 2604.15804. URL: <https://arxiv.org/abs/2604.15804>.
- [39] Qwen Team. «Qwen3-VL Technical Report». B: (2025). arXiv: 2511.21631. URL: <https://arxiv.org/abs/2511.21631>.
- [40] Ao Wang и др. «YOLOE: Real-Time Seeing Anything». B: (2025). arXiv: 2503.07465. URL: <https://arxiv.org/abs/2503.07465>.