

Санкт–Петербургский государственный университет

ДРУЖИНИН Максим Александрович

Выпускная квалификационная работа

***Каскад моделей для оценки качества аудио-визуального
образовательного контента и создания рекомендаций по
его улучшению***

Уровень образования: бакалавриат

Направление 02.03.01 «Математика и компьютерные науки»

Основная образовательная программа СВ.5189.2022 «Науки о данных»

Научный руководитель:

научный сотрудник, Лаборатория искусственного
интеллекта, математики и компьютерных наук им.

А. А. Маркова,

к.ф.-м.н. Николаев Максим Сергеевич

Рецензент:

доцент, Национальный исследовательский ядер-
ный университет «МИФИ»,

к.ф.-м.н. Кирова Валерия Орлановна

Санкт-Петербург

2026 г.

Содержание

Введение	3
Глава 1. Анализ предметной области и обзор существующих подходов	5
1.1. Особенности образовательного видео как объекта оценки . .	5
1.2. Существующие инструменты и их ограничения	6
1.3. Методы оценки технического аудио-визуального качества . .	8
1.4. Анализ содержания и тематическая сегментация	9
1.5. Управление вниманием и восприятие учебного контента . . .	9
1.6. Выводы и требования к системе	11
Глава 2. Реализация модулей анализа	13
2.1. Транскрипция	13
2.2. Техническое качество	14
2.2.1 Техническое качество аудио	14
2.2.2 Техническое качество видео	17
2.2.3 Агрегация в метрику технического качества	21
2.3. Флаги восприятия	22
2.4. Профиль подачи	26
2.5. Нарративная суммаризация	27
2.6. Метрика соответствия запросу	28
2.7. Пользовательский интерфейс	29
Список литературы	30

Введение

Объём образовательного видеоконтента на открытых платформах растёт быстрее, чем появляются инструменты для его оценки. Пользователь, выбирая между десятками лекций по одной теме, вынужден ориентироваться на лайки, просмотры и удержание, то есть метрики, разработанные для развлекательного контента и оптимизированные под клик, а не под передачу знаний. Создатель, в свою очередь, не получает содержательной обратной связи: что именно в его лекции не работает и для кого.

Ситуация воспроизводит логику «рынка лимонов» [1]: обе стороны действуют в условиях информационной асимметрии. Устойчивых сигналов, позволяющих сопоставить видео с образовательными целями конкретной аудитории, не существует.

Образовательное видео как объект оценки принципиально отличается от развлекательного: длинный таймлайн, высокая смысловая нагрузка, мультимодальность (речь, слайды, жесты), неравномерность интерактивности и критическая зависимость от контекста целевой аудитории. Ни одна из классических платформенных метрик эти характеристики не учитывает.

Существующие инструменты решают смежные задачи: Gemini позволяет суммаризовать видео по ссылке и генерировать таймкоды, StudyFetch — формировать конспекты и флеш-карты. Однако ни один из них не оценивает видео относительно конкретного пользовательского запроса и не даёт интерпретируемой аналитики для принятия решений.

В данной работе предлагается система автоматизированной оценки образовательного видеоконтента, формирующая аналитическую выдачу в зависимости от профиля пользователя: его роли, уровня подготовки, погружённости в тему и цели просмотра. Система оценивает видео по двум осям — форма и содержание, и включает: техническое качество аудио и видео, систему бинарных флагов восприятия на основе типологии Юнга, профиль подачи (академичность и инструментальность), адаптивную нарративную суммаризацию с тематической сегментацией и метрику соответствия запросу. Все оценки формируются без эталонного референса — исключительно на основе анализа самого видео.

Цель работы — разработать инструмент автоматизированной оценки ка-

чества и релевантности образовательного видеоконтента, формирующий интерпретируемую аналитику для обучающихся и авторов контента.

Задачи:

1. Провести обзор существующих подходов к оценке качества аудио-визуального контента и выявить их ограничения применительно к образовательному видео.
2. Разработать структуру каскадного анализа, охватывающего технические, поведенческие и содержательные аспекты.
3. Реализовать модули оценки: технического качества, флагов восприятия, профиля подачи, нарративной суммаризации и метрики соответствия запросу.
4. Разработать пользовательский интерфейс, обеспечивающий интерпретируемое представление результатов анализа.

Глава 1. Анализ предметной области и обзор существующих подходов

1.1 Особенности образовательного видео как объекта оценки

Образовательное видео отличается от развлекательного по ряду характеристик, принципиальных для задачи оценки. Во-первых, средняя продолжительность лекционного контента на порядок превышает длину развлекательного ролика, что усложняет анализ и делает глобальные агрегированные оценки малоинформативными. Во-вторых, контент мультимодален: речь лектора, слайды, жесты и мимика несут смысловую нагрузку одновременно и по-разному влияют на восприятие в зависимости от аудитории. В-третьих, интерактивность распределена неравномерно — зрительская активность концентрируется в отдельных точках видео и не отражает качество остального материала. Наконец, релевантность образовательного видео не является универсальной характеристикой: одна и та же лекция может быть ценной для студента первого курса и бесполезной для практикующего специалиста. Оценка, не учитывающая контекст пользователя, принципиально неполна.

Из этих особенностей следует, что метрики, разработанные для оценки развлекательного контента (удержание, лайки, просмотры, CTR) не применимы к образовательному видео: они оптимизированы под другую цель и не несут содержательной информации о качестве подачи или релевантности материала.

Перечисленные особенности определяют структуру требований к системе оценки. Мультимодальность и длинный таймлайн означают, что оценка должна охватывать несколько каналов одновременно: деградация любого из них на протяжённом видео непосредственно влияет на восприятие. Неравномерность интерактивности и высокая смысловая плотность требуют анализа внутренней организации материала, а не только его поверхностных атрибутов. Из этого следует разбиение на два измерения: **форма** — как материал представлен технически и как лектор его подаёт, и **содержание** — что именно представлено и насколько это соответствует образовательным целям аудитории.

Форма охватывает техническое качество аудио- и видеоряда: чёткость звука, уровень шума, качество изображения, стабильность съёмки. Однако тех-

нического качества недостаточно: два видео с одинаковыми техническими характеристиками могут восприниматься принципиально по-разному в зависимости от стиля подачи лектора — тональности, эмоциональной окраски, характера жестикуляции, степени формальности. Эти элементы управляют вниманием обучающегося и определяют когнитивную нагрузку независимо от содержания. Вопрос о том, как именно формализовать и измерить паттерны подачи, рассматривается в разд. 1.5.

Содержание определяется структурой и логикой изложения: наличием вводных и заключительных элементов, последовательностью и связностью тем, соответствием названия реальному материалу, а также глубиной и актуальностью: уровнем сложности, плотностью материала, необходимыми пресреквизитами. Релевантность при этом не является изолированным свойством видео: она возникает на пересечении содержательных характеристик и профиля конкретного пользователя — его уровня подготовки, погружённости в тему и цели просмотра.

1.2 Существующие инструменты и их ограничения

Автоматическая оценка образовательного видеоконтента в существующих системах сводится преимущественно к двум категориям метрик: технические атрибуты (разрешение, частота кадров, уровень аудио) и тематическая классификация (тема, ключевые концепции, наличие нежелательного контента) [2]. Эти метрики используются платформами для помощи пользователям при выборе контента, однако не затрагивают ни качество подачи, ни педагогическую структуру. В академической литературе предпринимались попытки оценить более глубокие аспекты. Shi и др. [3] исследуют корреляции мультимодальных признаков (аудио, текстовых и визуальных) с субъективными оценками качества лекций на MOOC-платформе, устанавливая что просодические характеристики и кросс-модальные признаки значимо предсказывают воспринимаемое качество и прирост знаний. Pan и др. [4] предлагают мультимодальный классификатор, обученный предсказывать качество преподавания по пяти аспектам (Clarity, Empathy, Classroom Interaction, Technical Management и Time Management) на размеченных записях очных и вебинарных занятий, достигая точности 0.898 на

бинарной классификации. Zhu и др. [2] предлагает иную постановку: модель симулирует студента, «посещает» лекцию, затем сдаёт тест по внешним учебным материалам темы, и качество видео приравнивается к результату этого теста. Объединяет все три подхода базовая установка: задача формулируется как автоматическое вынесение вердикта о качестве видео. При этом VCEval требует внешних учебных материалов по каждой теме, что ограничивает применимость к произвольному контенту, а Shi и др. [3] и Pan и др. [4] требуют размеченных обучающих данных и плохо переносятся на новые домены и форматы подачи.

Gemini API позволяет взаимодействовать с YouTube-видео напрямую по ссылке и генерировать суммаризации и таймкоды [5]. Недавно анонсированный Ask YouTube расширяет эту функциональность в сторону поиска по личной истории просмотров [6, 7]. Оба инструмента позиционируются как средства работы с контентом в режиме диалога, а не как аналитические системы оценки. Стоимость инференса по YouTube URL через Gemini API может быть существенной при масштабной обработке: видео токенизируется примерно как 300 токенов в секунду, поэтому один час видео даёт около 1.08 млн входных токенов. В зависимости от модели это составляет примерно от \$0.11 за час видео на Gemini 2.5 Flash-Lite до \$2.70+ на Gemini 2.5 Pro, без учёта стоимости выходных токенов [8]. Это ограничивает применимость подхода при массовом анализе YouTube-видео.

Платформы аналогичные StudyFetch больше ориентированы на образование, но решают задачу усвоения уже выбранного материала: генерация конспектов, флеш-карт, тестов [9, 10]. Они включаются после выбора видео и не затрагивают вопрос о том, подходит ли это видео конкретному пользователю.

Поскольку ни один из перечисленных подходов не ставит задачу иначе: предоставить пользователю структурированную интерпретируемую аналитику по нескольким измерениям одновременно (форме, содержанию), чтобы он мог сам принять решение о соответствии видео своим целям. Ниже рассматриваются методологические основы для каждого из них: методы оценки технического качества аудио и видео (разд. 1.3), подходы к анализу содержания и тематической сегментации (разд. 1.4) и психологические функции как инструмент формализации паттернов восприятия (разд. 1.5).

1.3 Методы оценки технического аудио-визуального качества

Качество аудио. Методы оценки качества речевого аудио делятся на intrusive и non-intrusive. Intrusive-методы сравнивают сигнал с эталоном: классический пример — PESQ (Perceptual Evaluation of Speech Quality) [11], стандарт для оценки качества телефонной речи. Такие методы дают точные результаты в контролируемых условиях, но неприменимы к пользовательскому контенту, где эталонная запись отсутствует по определению.

Non-intrusive методы предсказывают воспринимаемое качество непосредственно из сигнала. Среди них выделяется класс перцептивных моделей, обученных имитировать субъективную оценку слушателя по шкале MOS (Mean Opinion Score). Одним из актуальных представителей является DNSMOS P.835 [12], предсказывающая три независимых компонента: качество речевого сигнала, уровень фонового шума и интегральное качество.

Для анализа просодики и характеристик голоса используются инструменты фонетического анализа — в частности, Praat [13], обеспечивающий точное извлечение фундаментальной частоты (F0) и интенсивности. Монотонность речи как характеристика подачи устойчиво коррелирует с низкой вариативностью F0 и громкости [3]. Для оценки эмоциональной окраски речи активно развиваются трансформерные модели [14], которые показывают, что предыдущие подходы систематически занижали точность по валентности, и предлагают архитектуру, закрывающую эту нишу.

Качество видео. No-reference оценка качества видео — активная область исследований, особенно применительно к пользовательскому контенту (UGC). Reference-based метрики, такие как Peak Signal-to-Noise Ratio (PSNR), Structural Similarity Index Measure (SSIM) [15] и VMAF [16] показывают высокую точность в задачах сжатия и стриминга, где оригинальный сигнал доступен, однако неприменимы к оценке снятого пользователем контента без эталона. VMAF, в частности, активно используется Netflix для контроля качества трансляций, но требует оригинального мастер-файла для сравнения.

Классические no-reference подходы, такие как BRISQUE [17], работают на уровне отдельных кадров и оценивают резкость и артефакты в пространствен-

ной области. Более современные модели, например DOVER [18], рассматривают видео целиком и разделяют техническую и эстетическую составляющие качества, что актуально для контента с неоднородными условиями съёмки.

Отдельный класс задач — анализ визуальной сцены и поведения спикера. Для детектирования и трекинга человека в кадре применяются фреймворки компьютерного зрения реального времени, среди которых MediaPipe [19] обеспечивает надёжное извлечение ключевых точек лица и позы. Обнаружение монтажных переходов решается через детекторы смены сцен [20]. Задача распознавания текста в кадре (на доске или слайдах) решается средствами OCR.

1.4 Анализ содержания и тематическая сегментация

Задача тематической сегментации (разбиение на связные смысловые блоки) длинного текста или транскрипта изучается давно. Классический подход TextTiling [21] основан на лексической когезии: границы тем определяются по падению лексического сходства между соседними окнами текста. Метод интерпретируем и не требует обучения, однако чувствителен к шуму в транскрипте и плохо справляется с плавными тематическими переходами, характерными для лекционного контента.

Нейросетевые подходы на основе эмбедингов улучшают качество сегментации за счёт семантического представления текста, но по-прежнему работают с транскриптом как единственным модальным каналом. LLM-based подходы — в частности, Chapter-Llama [22] — используют языковые модели для одновременной сегментации и именования глав, приближаясь по качеству к авторской разметке на видео с чёткой структурой.

1.5 Управление вниманием и восприятие учебного контента

Установив что стиль подачи влияет на восприятие независимо от содержания, необходимо ответить на методологический вопрос: как его структурировать для измерения? Просто перечислить жесты, тональность, темп речи и эмоциональную окраску недостаточно — неясно ни как их группировать, ни в какую сторону и насколько сильно мерить. Нужна теоретическая база, задающая осмысленную декомпозицию.

Теория когнитивной нагрузки [23] и принципы мультимедийного обучения [24] дают хорошо валидированную основу: как устроена рабочая память, как распределяются когнитивные ресурсы между каналами, какие принципы дизайна снижают экзаменационную нагрузку. Эти фреймворки описывают универсальные механизмы восприятия и остаются актуальными ориентирами в проектировании учебного контента. Однако они отвечают на вопрос «что работает для большинства», и не затрагивают вопрос о том, почему одно и то же видео с одинаковым уровнем сложности вызывает у разных людей принципиально разную реакцию на стиль подачи.

Направление когнитивных стилей Riding [25] и модели стилей обучения (VARK и другие) описывают предпочтительные режимы обработки информации: визуальный, аудиальный, вербальный. Интуиция привлекательная, но последующие исследования показали, что влияние стиля обучения на результат опосредовано множеством других факторов (содержанием, контекстом, мотивацией) и не воспроизводится как самостоятельный эффект [26]. Обучение оказывается слишком комплексным процессом чтобы объяснять его через единственную переменную предпочтений.

Наиболее разработанную теоретическую базу для описания индивидуальных различий в обработке информации предложил Юнг в «Психологических типах» [27]. Он выделил четыре психологические функции: мышление — обработка информации через логику и причинно-следственные связи; ощущение — через конкретный чувственный опыт и детали реальности; интуиция — через паттерны, абстракции и возможности; чувство — через ценности, отношения и личную значимость. Функции попарно противоположны (мышление–чувство, ощущение–интуиция), и у каждого человека одна-две являются доминирующими, определяя какой тип информации воспринимается наиболее естественно, а какой требует дополнительных когнитивных усилий.

Юнговская типология получила широкое практическое применение через адаптации: MBTI [28] стал наиболее массовым инструментом, используемым преимущественно в HR, и модель Big Five [29] с непрерывными чертами личности с высокой надёжностью при повторном тестировании и кросс-культурной воспроизводимостью. Критика типологических инструментов обоснована: по данным Pittenger [30], до 50% людей получают другой MBTI-тип при повторном

тестировании через пять недель. Важно, однако, что критика бьёт по инструменту классификации, а не по исходному юнговскому наблюдению о различиях в доминирующих функциях.

Для настоящей работы типологический инструментарий не применяется по прямому назначению: мы не определяем психологический тип зрителя. Четыре юнговские функции используются как теоретическая рамка для структурированной декомпозиции понятия «управление вниманием»: каждая функция описывает режим обработки информации, нарушение которого создаёт специфический тип когнитивного напряжения. Это позволяет перейти от бесструктурного перечня свойств подачи к осмысленной группировке детектируемых паттернов.

1.6 Выводы и требования к системе

Методы оценки технического качества (разд. 1.3) предоставляют надёжные non-intrusive инструменты для анализа аудио- и видеоканала пользовательского контента без эталонного референса. Они дают сигнал на уровне физической воспринимаемости, но не объясняют что именно в подаче создаёт или снижает воспринимаемое качество.

Подходы к анализу содержания (разд. 1.4) работают со структурой транскрипта и семантическими переходами, но не учитывают техническую форму и пользовательский контекст. Академические работы по автоматической оценке образовательных видео [3, 4, 2] формулируют задачу как получение итоговой оценки качества; постановка «интерпретируемая аналитика под профиль пользователя» в литературе не встречается.

Анализ индивидуальных различий восприятия (разд. 1.5) показывает, что стиль подачи не сводится к набору отдельных признаков — для его анализа нужна структурирующая рамка. Юнговские функции рассматриваются в данной работе не как инструмент типирования зрителя, а как основа для группировки паттернов подачи, создающих когнитивное трение.

Совокупность рассмотренных направлений не закрывает ни одного из следующих пробелов:

- интеграция технического качества, содержания и паттернов восприятия в

единую выдачу;

- учёт пользовательского контекста (роли, уровня подготовки и цели просмотра) на всех уровнях анализа, а не как постобработка готового балла;
- интерпретируемая декомпозиция по измерениям вместо единого счёта;
- рассмотрение релевантности как функции пары «видео × пользователь», а не абсолютного свойства контента;
- локализация сигналов по таймкодам.

Эти пробелы непосредственно определяют требования к системе: мультимодальный каскадный анализ с разделением формы и содержания на уровне модулей; no-reference архитектура без дообучения собственных моделей; пользовательский контекст как параметр, пронизывающий все слои, а не применяемый в конце; выдача, структурированная по измерениям и допускающая содержательную интерпретацию каждого компонента.

Перечисленные требования определяют архитектуру системы, описанную в ??.

Глава 2. Реализация модулей анализа

2.1 Транскрипция

Транскрипт является важным ресурсом для большинства слоев. Он потребляется модулями оценки качества аудио, флагов восприятия, профиля подачи и нарративной суммаризации.

В качестве источника транскрипта выбрана модель Whisper [31], а не автоматические субтитры платформы. Принципиальное преимущество такого подхода независимость от источника контента: Whisper принимает на вход произвольный аудиопоток и не предполагает никакой привязки к конкретной платформе. Поскольку Whisper принимает на вход аудиофайл, а не платформенный URL, модуль транскрипции не зависит от источника контента, то есть при смене платформы достаточно заменить только шаг скачивания через `ut-dlp`, всё остальное продолжает работать без изменений. Второе преимущество — контроль над качеством транскрипции: выбор размера модели, параметров инференса и постобработок полностью находится на стороне разработчика, тогда как платформенные субтитры предоставляются «как есть» без возможности влияния на них.

Образовательный контент предъявляет к транскрипции повышенные требования: лекции содержат специализированную терминологию, формулы, и аббревиатуры, которые хуже распознаются компактными моделями. По этой причине используется вариант `large` — крупнейший из доступных, обеспечивающий наилучшее покрытие предметной лексики. При этом применяется дистиллированная версия `large-v3-turbo` [32], разработанная на основе методологии `Distil-Whisper` [33], которая существенно ускоряет инференс при ограниченной деградации точности.

Транскрипция реализована через библиотеку `faster-whisper` [34] — реализацию Whisper на базе `CTranslate2`, обеспечивающую более быстрый инференс по сравнению с оригинальной имплементацией без изменения логики работы модели. Параметр `condition_on_previous_text=False` выключает авторегрессионное «сглаживание» транскрипта, то есть модель реже исправляет слова-паразиты и просторечия, что важно для последующего анализа стиля

речи.

На выходе модуль возвращает список сегментов с текстом и временными метками (start, end в секундах), полный текст транскрипта, длительность и WPM, причем по речевым сегментам, а не по полной длине видео. $[WPM = N_{\text{words}} / (T_{\text{speech}} / 60)]$

2.2 Техническое качество

2.2.1 Техническое качество аудио

Оценка качества аудио строится на двух уровнях: перцептивном и техническом. На выходе модуль возвращает нормированный скор от 0 до 10 и список выявленных проблем (issues).

Перцептивная оценка: DNSMOS. Базой служит DNSMOS P.835 [12] — по-reference перцептивная модель Microsoft, предсказывающая воспринимаемое качество речи без эталонного референса. Модель возвращает три компонента: разборчивость речевого сигнала (sig_mos), уровень фонового шума (bak_mos) и интегральное качество (ovrl_mos). Разложение на компоненты позволяет локализовать природу проблем: низкий bak указывает на шум окружения, низкий sig — на проблемы с голосом.

Из рассмотренных non-intrusive подходов DNSMOS выбрана потому что она обучена специфически на речи, а не на общем аудио, что делает её более надёжной на лекционном материале с фоновым шумом аудитории, эхом и реверберацией. Альтернативная модель ViSQOL [35], кроме того что является reference моделью, так ещё и возвращает единый балл, не позволяющий определить источник проблем.

Компоненты DNSMOS агрегируются во взвешенный показатель с акцентом на общее качество и разборчивость речи:

$$d = 0.50 \cdot \text{ovrl} + 0.35 \cdot \text{sig} + 0.15 \cdot \text{bak}. \quad (1)$$

DNSMOS возвращает значения по шкале от 1 до 5, однако для итоговой метрики системы показатель переводится в шкалу 0–10, что повышает удобство

интерпретации и позволяет согласовать аудио-оценку с остальными компонентами пайплайна. Поэтому взвешенный показатель переводится в итоговую шкалу через сигмоидальное преобразование:

$$base = \sigma(d, c=2.8, k=3) \times 10. \quad (2)$$

Центр сигмоиды выбран равным 2.8, то есть немного ниже теоретической середины шкалы DNSMOS. Такое смещение отражает эмпирическое наблюдение на валидационной выборке: лекционные записи среднего воспринимаемого качества часто получают DNSMOS ниже формальной середины шкалы. Поэтому центр 2.8 позволяет лучше разделять средние и хорошие записи, не завышая итоговые оценки для явно проблемного аудио.

Технические метрики и препроцессинг. Перед техническим анализом аудио разбивается на речевые сегменты и паузы через silero-VAD [36] — лёгкую нейросетевую модель. SNR вычисляется как отношение RMS речевых сегментов к RMS пауз: этот подход не требует отдельной модели шумоподавления и даёт стабильные результаты на лекционном аудио. Громкость оценивается как LUFS через `pyloudnorm` — перцептивно взвешенный стандарт вещательного контента, позволяющий сравнивать субъективно воспринимаемую громкость между видео независимо от пиковой амплитуды (ITU-R BS.1770) [37, 38].

Клиппинг детектируется тремя независимыми метриками. Прямая метрика `clipping_ratio` считает долю сэмплов с амплитудой выше порога 0.99. Однако YouTube нормализует аудио при загрузке, поэтому прямой порог по амплитуде оказывается не всегда легко интерпретируемым: видео с реальными проблемами динамического диапазона в исходной записи (зажатые верхи, перегруженный микрофон) после нормализации могут иметь допустимую пиковую амплитуду. Для устойчивого обнаружения добавлены две формозависимые метрики: `crest_factor` (отношение пика к RMS, так как у клипированного сигнала пики срезаны, поэтому `crest factor` аномально мал даже после нормализации) и `flattened_peaks_ratio` (доля плоских участков на пиках является прямым признаком формы «срезанной верхушки», который сохраняется при любом масштабировании амплитуды).

Агрегация аудио сора. Технические метрики применяются как мультипликативные штрафы к базовому DNSMOS скору. Мультипликативная схема выбрана потому что деградации накапливаются: одновременно плохой SNR и клиппинг дают более тяжёлый результат, чем каждая из проблем в отдельности. Каждая техническая метрика переводится в штрафной коэффициент $k_i \in [0, 1]$. Чтобы совокупность мелких недостатков не обрушивала скор диспропорционально, суммарный штраф ограничен снизу: $mult = \max(0.60, \prod k_i)$.

Помимо штрафов, применяются условные потолки. Некоторые проблемы принципиально ограничивают воспринимаемое качество и не компенсируются никакими другими метриками: сильный клиппинг означает физическое искажение речи, а очень низкий SNR делает понимание речи затруднённым вне зависимости от остального. В таких случаях итоговый скор не может превысить заданный потолок. Конкретные пороги штрафов и потолков подобраны эмпирически на валидационной выборке.

Финальный аудио скор:

$$audio_score = \max(0.5, \min(ceiling, base \times mult)) \quad (3)$$

где $mult = \max(0.60, \prod k_i)$ — совокупный штрафной коэффициент, $ceiling$ — условный потолок (10 при отсутствии критических проблем), ограничение снизу 0.5 исключает нулевые оценки при частичных данных.

Компонент	Что входит	Роль
<i>base</i>	DNSMOS через сигмоиду	основа
<i>mult</i>	$k_{clipping} \cdot k_{SNR} \cdot k_{LUFS}$	штраф, ≥ 0.60
<i>ceiling</i>	min по clipping и SNR	жёсткий потолок

Таблица 1: Компоненты агрегации аудио сора

Помимо сора, модуль возвращает список выявленных проблем (*issues*) с указанием метрики и уровня критичности — они используются в пользовательском интерфейсе для потенциального содержательного объяснения оценки.

2.2.2 Техническое качество видео

Оценка качества видео построена по той же логике что и аудио: перцептивная модель даёт базовый скор, интерпретируемые метрики применяются как мультипликативные штрафы, образовательно-специфичные компоненты могут как снижать так и повышать итоговый результат. На выходе модуль возвращает нормированный видео скор от 0 до 10 и список выявленных проблем (*issues*).

Извлечение кадров. Видеопоток скачивается в формате H.264 (ограничение 1080p), метаданные (разрешение, FPS, битрейт, кодек) извлекаются через *ffprobe*. Дальнейший анализ работает с двумя наборами кадров. Кадры качества извлекаются с частотой 0.1 fps через *ffmpeg* — одного кадра на десять секунд достаточно для оценки статических характеристик (резкость, экспозиция, контраст, артефакты) при существенном снижении вычислительной нагрузки. Отдельный набор кадров с более высокой частотой используется для анализа мерцания, где важна временная динамика между соседними кадрами.

Перцептивная оценка: DOVER. Базой служит DOVER [18] — no-reference модель, обученная на UGC-датасетах и оценивающая видео с технической и эстетической точек зрения одновременно. Модель возвращает единый *fused score* от 0 до 1. Из доступных no-reference подходов DOVER выбран потому что он обучен специфически на пользовательском контенте (а не на студийных записях), что соответствует природе лекционного видео с неоднородными условиями съёмки.

Как и в случае аудио, скор переводится в шкалу 0–10 через сигмоиду; параметры (центр 0.4, крутизна 10) подобраны эмпирически. Для локализации природы проблем применяются интерпретируемые метрики ниже.

Артефакты сжатия: BRISQUE. BRISQUE [17] оценивает отклонение от статистики естественных сцен — компрессионные артефакты, блочность и зерно нарушают это распределение.

Однако, в итоговую агрегацию не включён. По результатам тестирования метрика не показала устойчивой корреляции ни с субъективным восприятием

качества, ни с другими метриками модуля. Например, видео с белой доской и слайдами систематически получали высокий скор — однородный белый фон с текстом интерпретируется как артефакт компрессии. На тестовой выборке такие видео получали медианный BRISQUE (по шкале 0-100, где меньше - лучше) около 99 при объективно приемлемом качестве. Она сохраняется в raw-выдаче для диагностических внутренних целей и потенциальных будущих улучшений.

Детальные метрики. *Резкость* оценивается через дисперсию Лапласиана [39]. Для агрегации используется 10-й перцентиль по всем кадрам, а не медиана: наихудшие 10% кадров значимее для воспринимаемого качества, чем типичный кадр.

Экспозиция анализируется по V-каналу в HSV-пространстве: вычисляются средняя яркость, доля пересвеченных и недосвеченных пикселей. *Контраст* оценивается как стандартное отклонение яркости в рамках кадра. *Мерцание* — как средняя попиксельная разница яркости между соседними кадрами. Потенциальный источник такого рода искажений, например, флуоресцентные лампы встречающиеся в записях лекций вузов.

Стабильность оценивается через фильтр `vidstabdetect` библиотеки `vid.stab` [40], интегрированной в `ffmpeg`. Алгоритм строится на `feature matching` и оценке глобальной трансформации между кадрами, а результат это среднее смещение в пикселях. Выбор `vidstabdetect` над альтернативами (оптический поток Лукаса-Канаде, попиксельная разница) обусловлен тем, что он оценивает именно движение камеры, а не суммарное движение в кадре включая спикера.

Временная консистентность отражает равномерность условий съёмки на протяжении видео: вычисляется относительное стандартное отклонение резкости и яркости по всем кадрам. Высокая консистентность указывает на стабильные условия съёмки, а резкие выбросы — на смену освещения или перефокусировку.

Образовательно-специфичные метрики. Два компонента специфичны для образовательного формата и не являются метриками качества видео в общем случае.

Видимость спикера отслеживается через `MediaPipe` [19] (модель `blaze_face_f`

Вычисляются доля кадров с обнаруженным лицом и медианный размер лица как доля площади кадра. Эти признаки сохраняются как диагностические, но не входят напрямую в итоговый video score: отсутствие спикера в кадре не всегда является дефектом образовательного видео, поскольку скринкасты, анимированные объяснения и записи работы с доской могут быть полностью валидными без визуального присутствия лектора. Тем не менее для авторов контента такая информация может использоваться как рекомендация по улучшению визуального контакта с аудиторией.

Читаемость доски или экрана оценивается в три слоя. Сначала YOLOE [41] детектирует наличие доски или экрана и возвращает сегментационную маску. По маске OpenCV вычисляет засветку (доля ярких пикселей) и контраст текста.

Наконец, Qwen3-VL-Plus оценивает читаемость по пятибалльной шкале на пяти равномерно распределённых кадрах — модель определяет тип поверхности (физическая доска, маркерная доска, проектор) и формулирует конкретные проблемы. Семантическая оценка через VLM необходима потому что читаемость текста не сводится к контрасту и засветке: рукописные формулы, угол съёмки и качество маркера не улавливаются классическими CV-дескрипторами. Промпт сформулирован так, чтобы оценивать исключительно физические условия восприятия контента на носителе: равномерность и качество освещения, контраст между контентом и фоном, чёткость и размер элементов относительно камеры. Модель явно инструктирована не оценивать язык, почерк, тип контента или временное перекрытие спикером — неровный, но контрастный почерк соответствует уровню 4–5. Такая формулировка делает оценку независимой от предметной области и типа носителя: классная доска, маркерная доска, проекционный экран и планшет оцениваются по одной шкале. Модель возвращает `readability_level` (1–5), `readability_score` (0–1), тип поверхности (`surface_type`) и главные проблемы (`main_issues`). По пяти кадрам агрегируется медиана уровня и среднее сора.


Шкала 1–5 снабжена якорными описаниями для каждого уровня:

1. Засветка или тень физически уничтожают контент;
2. Значительная часть контента теряется;

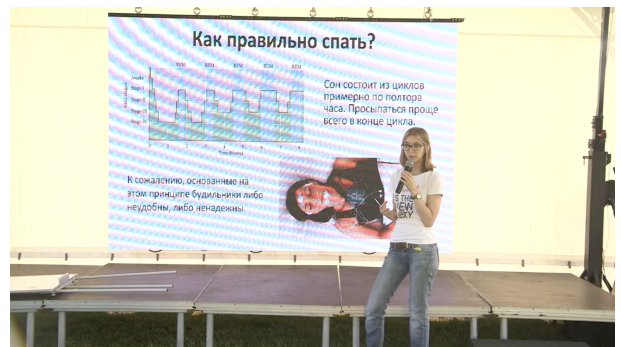
3. Общая картина понятна, детали теряются;
4. Контент воспринимается без затруднений, незначительные проблемы;
5. Равномерное освещение, высокий контраст, всё чётко различимо.

Якорные описания оказались необходимы: без них модель либо систематически занижала оценки, интерпретируя любые несовершенства как серьёзные проблемы, либо завышала, не понимая что именно является критерием оценки. Дискретная шкала с якорными описаниями используется далее и в текстовых LLM-модулях, так как показала свою эффективность и там: LLM надёжнее выполняет категориальные суждения с опорой на якоря, чем присваивает абсолютные числа в непрерывном диапазоне.

В качестве примера, уровень 3 может достигаться принципиально разными причинами — что иллюстрирует рис. 1.



(a) Меловая доска



(b) Проекционный экран

	(a) Меловая доска	(b) Проекционный экран
surface_type	blackboard	screen
readability_level	3	3
main_issues	partial_obscuration, faint_writing, smudges	glare, smudges, overexposure
Интерпретация	Доска плохо стёрта, часть записей плохо различима.	Артефакты от экрана проектора и камеры, при этом текст читаем.

Рис. 1: Два примера с `readability_level = 3`: одинаковый скор при разных причинах ухудшения читаемости. Левый кадр — меловая доска (МГУ, лекция по мат. анализу), правый — проекционный экран (TED-style лекция на открытой площадке).

Агрегация видео сора. База — DOVER-скор через сигмоиду (центр 0.4, параметры подобраны эмпирически). Четыре метрики применяются как мульти-

пликативные штрафы: резкость (*blur*), мерцание (*flicker*), стабильность (*stability*) и временная консистентность (*consistency*) (высокое стандартное отклонение резкости по кадрам). Каждая метрика переводится в штрафной коэффициент $k_i \in [0, 1]$ и при этом суммарный штраф ограничен: $mult = \max(0.60, \prod k_i)$.

Читаемость доски добавляется аддитивно, а не мультипликативно. Логика: штрафы за резкость, мерцание и стабильность относятся к техническому качеству съёмки — они ухудшают сигнал. Доска же является содержательным элементом: её читаемость не связана с качеством съёмки, но напрямую влияет на образовательную ценность видео. Аддитивная дельта от -1.0 до $+1.5$ отражает этот вклад отдельно от технической составляющей.

Для трёх критических дефектов дополнительно применяются условные потолки: сильное размытие, сильное мерцание или выраженная нестабильность принципиально ограничивают воспринимаемое качество, и никакие другие характеристики это не компенсируют.

$$video_score = \max(0.5, \min(ceiling, base \times mult + board_delta)) \quad (4)$$

Компонент	Что входит	Роль
<i>base</i>	DOVER через сигмоиду	основа
<i>mult</i>	$k_{blur} \cdot k_{flicker} \cdot k_{stability} \cdot k_{consistency}$	штраф, ≥ 0.60
<i>board_delta</i>	читаемость доски (Qwen3-VL, 1–5)	бонус/малус, $[-1.0, +1.5]$
<i>ceiling</i>	min по blur, flicker, stability	жёсткий потолок

Таблица 2: Компоненты агрегации видео сора

2.2.3 Агрегация в метрику технического качества

Итоговый скор технического качества объединяет аудио и видео оценки через гармоническое среднее:

$$technical_score = \frac{2 \times audio_score \times video_score}{audio_score + video_score} \quad (5)$$

Гармоническое среднее выбрано намеренно: оно автоматически штрафует асимметрию между компонентами. Арифметическое среднее видео 8/10 и

аудио 2/10 даёт 5.0 — результат, не отражающий реальное качество просмотра. Гармоническое среднее тех же значений даёт 3.2. Логика та же что и в F1-мере в задачах *information retrieval*, где гармоническое среднее *precision* и *recall* штрафует модели с сильным дисбалансом между ними: лекция с великолепным видео но нечитаемым звуком остаётся плохой лекцией.

В табл. 3 приведены примеры из валидационной выборки, иллюстрирующие разные сценарии соотношения аудио- и видеооценок.

Сценарий	Аудио	Видео	Итог
Студийная запись урока с высоким качеством видео	6.8	9.1	7.8
Хорошая запись вузовской лекции	7.8	7.7	7.75
Запись преподавателя онлайн-школы с хорошим аудио	8.1	5.3	6.4
Старая запись того же канала со слабым видео	7.3	4.3	5.4
Вузовская лекция со слабым аудио при приемлемом видео	4.0	6.7	4.9
Старая запись вузовской практики с низким качеством обоих каналов	0.5	0.6	0.5

Таблица 3: Примеры агрегации аудио- и видеооценок через гармоническое среднее. Таблица показывает, что итоговый технический скор снижается при дисбалансе между каналами: при слабом аудио или видео итог оказывается ближе к худшему компоненту, чем к лучшему.

2.3 Флаги восприятия

Флаги восприятия — бинарные сигналы, фиксирующие паттерны подачи, которые негативно влияют на восприятие у конкретного типа аудитории. Каждый флаг соответствует одному из четырёх типов типологии Юнга [27] и детектирует нарушение его доминирующего канала восприятия. Флаги не взаимоисключающие — несколько могут сработать одновременно.

Концепция флагов возникла из наблюдения, что одни и те же проблемы подачи систематически повторяются и по-разному влияют на разных зрителей. Перенос типологии на задачу детектирования был откалиброван через опрос 52 человек из образовательной среды, знакомых со своим типом. Участники верифицировали соответствие между паттернами подачи и тем, что реально мешает восприятию для каждого типа.

Часть паттернов требует понимания смысла — наличие образности, характер промежуточных итогов, соответствие эмоционального тона контексту. Классические NLP-методы здесь недостаточны: нужна семантика процесса, а не поверхностные признаки текста. Для таких задач применяется LLM в формате бинарных вопросов с примерами из текста — примеры делают ответы верифицируемыми. Для LLM-анализа во всех флагах (и далее) используется DeepSeek V4 [42] — модель выбрана за сильные reasoning-способности, надёжную работу с русскоязычным текстом и стоимость инференса, не сопоставимую с моделями сравнимого качества. LLM-вызовы флагов встроены в существующий нарративный модуль (о котором будет дальше) и не создают дополнительных расходов на контекст.

Для задач с нативным аудио- и визуальным входом применяется семейство Qwen. Выбор обусловлен тем, что моделей с нативной обработкой аудио и видео напрямую — без промежуточной транскрипции или извлечения признаков — на открытом рынке крайне мало, а доступных по стоимости и воспроизводимых локально ещё меньше. Семейство Qwen закрывает обе задачи: Qwen-Omni [43] обрабатывает аудиопоток напрямую, Qwen3-VL [44] — видеокadres. Дополнительным преимуществом является наличие компактных открытых версий для локального тестирования с последующим переходом на API-версии для production. Тестирование визуального модуля проводилось на Qwen3-VL-8B локально — модель показала достаточное качество на задаче оценки визуальной опрятности, после получения API принято решение перейти на Qwen3-VL-Plus: это освобождает локальный compute для других модулей и даёт прирост точности без изменения логики. Аудиоветка семейства (Qwen2.5-Omni-7B локально и Qwen2.5-Omni-Plus через API) тестировалась для задачи детектирования артикуляционных дефектов речи — результаты и причины неудачи описаны в разделе флага Аудио дисбаланс.

Флаг «Аудио Дисбаланс» (Логик) Логический тип воспринимает информацию преимущественно через аудиальный канал — звук является его основным каналом потребления контента. Флаг срабатывает когда речь или звук мешает восприятию: фоновые шумы, тембральные особенности, слова-паразиты и просторечия.

Технические метрики (DNSMOS ovrl/sig/bak, SNR, клиппинг, LUFs) переиспользуются из модуля 4.1 без повторного расчёта — они напрямую покрывают то, что раздражает логика. Слова-паразиты, просторечия и орфоэпические ошибки детектируются LLM на транскрипте в формате бинарных вопросов с примерами из текста — словарный подход не используется, поскольку пропускает нестандартные паразиты и региональные просторечия.

Отдельно исследовалась задача детектирования артикуляционных дефектов речи (картавость, нестандартный тембр) — логики тратят значительно больше когнитивных ресурсов на восприятие нестандартного звукоряда. Были последовательно проверены три подхода. Whisper avg_logprob: гипотеза состояла в том, что модель будет менее уверена при транскрипции дефектной речи — тесты опровергли это, нормальные видео нередко давали более низкий logprob из-за сложности терминологии, а не качества произношения. Praat jitter/shimmer/HNR: клинические нормы рассчитаны на студийные записи изолированных гласных — на YouTube-аудио с естественной речью все лекторы, включая тех с очевидными дефектами, попадали в «патологическую» зону без какого-либо деления. Qwen Omni (тестировались Qwen2.5-Omni-7B локально и Qwen2.5-Omni-Plus через API): аудио LLM обучены на выравнивании контента, а не паралингвистических характеристиках — модели возвращали false на видео с очевидными дефектами. Корневая проблема: не существует датасета с текстовыми описаниями дефектов речи, на котором можно было бы обучить или настроить модель. Детектирование дефектов речи исключено из текущей реализации как нерешённая подзадача.

Флаг «Смысловая унылость» (Интуит) Интуитивный тип воспринимает информацию через идеи, паттерны и концепции — ему важна смысловая динамика и образность изложения. Флаг срабатывает когда лекция семантически бедна: нет крючка в начале, нет метафор и аналогий, промежуточные итоги дублируют сказанное вместо синтеза, лектор читает слайды дословно.

Основной инструмент — LLM-анализ транскрипта: модель отвечает на серию бинарных вопросов с примерами из текста (наличие hook в первые минуты, использование метафор, характер промежуточных итогов, авторская позиция). Формат с примерами позволяет верифицировать ответы и снизить риск галлю-

цинаций. Этот LLM-вызов встроен в существующий нарративный модуль и не создаёт дополнительных расходов на контекст.

Дублирование слайдов детектируется отдельно. Сначала YOLOE [41] определяет наличие доски или экрана в кадре — запускать OCR на каждом кадре без проверки наличия текстовой поверхности расточительно, YOLOE как open-vocabulary детектор справляется с этой задачей без дообучения под конкретный тип сцены. Текст извлекается через EasyOCR — он выбран за нативную поддержку кириллицы при приемлемом качестве: лекционный материал часто смешивает русский и английский, Tesseract на таком материале даёт существенно хуже результаты. Далее семантическая близость между речью лектора и текстом слайда измеряется NLP-методами — высокое сходство сигнализирует о дублировании.

Флаг «Эмоциональный дисбаланс» (Эмоция) Эмоциональный тип воспринимает через атмосферу и отношения — ему важна живость и уместность эмоционального тона. Флаг срабатывает в двух противоположных случаях: лектор читает механически без эмоциональной окраски, либо эмоциональный напор не соответствует контексту.

Эмоциональная окраска речи оценивается через модель audEERING [14] — трансформерную SER-архитектуру, специально разработанную для закрытия valence gap: предыдущие поколения SER-моделей стабильно предсказывали arousal, но систематически ошибались по валентности (позитивность / негативность эмоции). Модель применяется по скользящим окнам на аудиосегментах — вычисляется распределение эмоциональных состояний и их вариативность во времени. Именно вариативность является ключевым признаком: флаг детектирует не конкретную эмоцию, а её отсутствие или избыток относительно контекста. Модель обучена на английских данных, однако просодические паттерны эмоциональной речи переносятся между языками устойчиво, что подтверждается в том числе авторами работы.

Флаг «Визуальный шум» (Сенсорик) Сенсорный тип воспринимает через визуальный канал и реальность происходящего в кадре. Флаг срабатывает когда визуальный ряд перегружен раздражителями: резкие склейки с большим изме-

нением картинки между ними, хаотичное движение в сцене, перегруженность кадра.

Монтажные склейки детектируются через PySceneDetect [20] — лёгкий инструмент без зависимостей от нейросетевых моделей, работающий напрямую на видеопотоке. Резкость перехода оценивается через OpenCV и MediaPipe: позиция лица лектора сравнивается между кадрами до и после склейки — резкое смещение спикера в кадре является маркером дезориентирующего монтажа.

Общая визуальная опрятность и перегруженность сцены требует семантического понимания картинки и не поддаётся надёжной формализации через классические дескрипторы — яркость, контраст и оптический поток не улавливают смысловую перегруженность кадра. Для этой задачи применяется Qwen3-VL. Тестирование проводилось локально на Qwen3-VL-8B — модель показала достаточное качество на задаче оценки визуальной опрятности при разумном потреблении памяти. После получения доступа к API принято решение перейти на Qwen3-VL-Plus: это освобождает локальный compute для других модулей пайплайна и даёт прирост точности без изменения логики модуля.

2.4 Профиль подачи

Профиль подачи описывает глобальную педагогическую ориентацию лекции по двум независимым осям: академичность и инструментальность. Важно, что это не про поверхностные признаки текста — наличие формул, определений или примеров, а скорее про глобальную цель занятия. Лекция по линейной алгебре на, условном, эконофাকে и на матфাকে могут иметь близкий лексический состав, иметь теоремы и аксиомы, но принципиально разную педагогическую ориентацию — одна объясняет чтобы применять, другая строит строгую теорию.

Рассмотренные подходы. Первым был протестирован zero-shot NLI: академичность и инструментальность формулировались как гипотезы, модель возвращала вероятности entailment. Результатом является полная сатурация: все видео получили 9.5–10.0 по обеим осям. NLI-модели обучены на формальном entailment общего характера и не различают педагогические ориентации внутри образовательного дискурса — они фиксируют формальное наличие признаков («в тексте есть определения» значит true), а не глобальную цель занятия.

Следующая попытка — LLM с непрерывной шкалой 0–1. Та же проблема в другом виде: без якорных точек модель не имеет опоры для дифференциации, оценки кластеризовались в узкой зоне.

Выбранный подход. Дискретная пятибалльная шкала с якорными описаниями для каждого уровня. Академичность: от 1 («разговорное объяснение на пальцах без формальных определений») до 5 («аксиоматическое построение предмета, доказательства, строгая структура понятий»). Инструментальность: от 1 («объяснение без применения — обсуждает, мотивирует, но не учит действовать») до 5 («tutorial: пошаговые процедуры, вычисления, код, результат который можно воспроизвести»). Внутри каждого уровня модель дополнительно выставляет score 0.0–1.0 как точную позицию это даёт непрерывность при сохранении категориальной структуры.

Оси независимы, так как семинар высокого уровня с теорией и задачами может получить 5 по академичности и 4 по инструментальности одновременно. Модель предоставляет evidence (конкретные цитаты и наблюдения из транскрипта) для каждой оценки для валидации. Используется LLM с включённым thinking — reasoning-лог показывает что модель действительно анализирует педагогическую структуру, а не просто сопоставляет паттерны.

2.5 Нарративная суммаризация

Нарративный модуль формирует текстовую часть выдачи это компонент системы, который читается как связный текст, а не набор метрик, и состоит из трёх компонентов: тематической сегментации с таймкодами, педагогического анализа и собственно нарратива.

Тематическая сегментация. Транскрипт разбивается на смысловые блоки с таймкодами и названиями тем. Гранулярность адаптируется под цель просмотра: пользователь с целью «составить общее представление» получает укрупненные блоки, пользователь с целью «последовательно изучить тему» — детальную разбивку с таймкодами каждого подраздела.

Педагогический анализ. LLM оценивает структурные характеристики лекции относительно заявленной темы и пользовательского профиля: пресреквизиты (что нужно знать чтобы смотреть), пробелы в теме (что заявлено в

названии но не раскрыто), плотность материала, соответствие названия содержанию.

Нарратив. Неожиданно наиболее нетривиальный компонент. Задача формулируется так: текст от лица человека, который посмотрел видео и понял в чём его ценность это именно не пересказ тем, а объяснение что именно примечательно в этом видео для конкретного пользователя с его профилем. Пересказ («лектор объясняет пределы функций») не помогает принять решение о просмотре, нарратив («для бакалавра первого курса который хочет разобраться с нуля — редкий пример где строгость не жертвуется ради доступности») — помогает.

В ходе разработки было установлено что качество нарратива зависит от модели и режима инференса. Тестировались несколько конфигураций: модели без thinking давали формальные пересказы структуры вместо оценки ценности, модели с thinking но без достаточного reasoning-бюджета давали поверхностный анализ. Итоговая конфигурация использует LLM с включённым thinking и достаточным бюджетом токенов на рассуждение — reasoning-лог показывает, что модель отмечает редкие педагогические приёмы, конкретные понятия, выделяет что отличает видео от аналогичных.

2.6 Метрика соответствия запросу

Метрика соответствия запросу — интегральная оценка по шкале 0–100, агрегирующая все вычисленные компоненты с учётом пользовательского профиля. Одно и то же видео получает разный балл для школьника и специалиста, для цели «составить общее представление» и «последовательно изучить тему». Дополнительно учитываются метаданные: соответствие названия содержанию и наличие у канала связанной серии лекций.

Методология взвешивания компонентов находится в разработке: текущие веса подобраны эмпирически на валидационном датасете и требуют дальнейшей калибровки.

2.7 Пользовательский интерфейс

Интерфейс решает две задачи: минимизировать усилия пользователя на входе и сделать выдачу интерпретируемой без дополнительного контекста.

Выбор четырёх входных параметров был нетривиальным упражнением: хотелось покрыть ключевые сценарии использования при минимальном количестве полей. Итоговый набор — роль, уровень образования, погружённость в тему, цель просмотра — признан минимально достаточным после нескольких итераций.

Поскольку пайплайн ресерческий и занимает несколько минут, пользователю отображаются этапы обработки в реальном времени, включая появление транскрипта по мере его готовности. Важно для ресурсоёмкого процесса, чтобы пользователь понимал что происходит.

На экране результатов пользовательские параметры остаются видны постоянно, а всё остальное интерпретируется относительно них. Метрики интерактивны: при нажатии раскрывается описание и интерпретация применительно к конкретному видео. Флаги реализованы как бинарные индикаторы — числовые шкалы для них не используются, поскольку создавали бы ложное ощущение точности. Профиль подачи визуализирован как спидометр со смещением от центра, что передаёт доминирующую ориентацию нагляднее двух отдельных чисел. Таймкоды в нарративной части кликабельны и переключают встроенный YouTube-плеер на нужный момент.

Список литературы

- [1] George A. Akerlof. «The Market for “Lemons”: Quality Uncertainty and the Market Mechanism». В: *Quarterly Journal of Economics* 84.3 (1970), с. 488—500. DOI: 10.2307/1879431. URL: <https://doi.org/10.2307/1879431>.
- [2] Xiaoxuan Zhu и др. «VCEval: Rethinking What is a Good Educational Video and How to Automatically Evaluate It». В: (2025). arXiv: 2407.12005. URL: <https://arxiv.org/abs/2407.12005>.
- [3] Jing Shi и др. «Investigating Correlations of Automatically Extracted Multimodal Features and Lecture Video Quality». В: *Proceedings of the 1st International Workshop on Search as Learning with Multimedia Information (SALMM '19)*. ACM, 2019, с. 11—19. DOI: 10.1145/3347451.3356731. URL: <https://doi.org/10.1145/3347451.3356731>.
- [4] Yueran Pan и др. «A Multimodal Framework for Automated Teaching Quality Assessment of One-to-many Online Instruction Videos». В: *Proceedings of the 26th International Conference on Pattern Recognition (ICPR)*. IEEE, 2022, с. 1777—1783. URL: <https://ieeexplore.ieee.org/document/9956185>.
- [5] Google Developers. *Building with Gemini 2.0: Video Understanding*. 2024. URL: <https://www.youtube.com/watch?v=Mot-JEU26GQ> (дата обр. 23.05.2026).
- [6] Jay Peters. *Google is Testing AI Chatbot Search for YouTube*. 2026. URL: <https://www.theverge.com/streaming/919441/google-ask-youtube-ai-chatbot-search> (дата обр. 23.05.2026).
- [7] The Keyword. *YouTube Tests “Ask YouTube” AI Search Experience*. 2026. URL: <https://www.thekeyword.co/news/ask-youtube-ai-search> (дата обр. 23.05.2026).
- [8] Google Developers. *Video Understanding*. 2026. URL: <https://ai.google.dev/gemini-api/docs/interactions/video-understanding> (дата обр. 23.05.2026).

- [9] StudyFetch. *StudyFetch Documentation: Your Complete Guide to Mastering StudyFetch's AI-Powered Learning Tools*. 2024. URL: <https://www.studyfetch.com/> (дата обр. 23.05.2026).
- [10] Laxu AI Editorial Team. *Laxu AI vs Quizlet vs Anki vs StudyFetch vs Knowt: Best Flashcard App in 2026?* 14 янв. 2026. URL: <https://laxuai.com/blog/laxu-ai-vs-quizlet-vs-anki-comparison> (дата обр. 23.05.2026).
- [11] ITU-T. *Perceptual Evaluation of Speech Quality (PESQ): An Objective Method for End-to-End Speech Quality Assessment of Narrow-Band Telephone Networks and Speech Codecs*. P.862. International Telecommunication Union. 2001. URL: <https://www.itu.int/rec/T-REC-P.862> (дата обр. 23.05.2026).
- [12] Chandan K. A. Reddy, Vishak Gopal и Ross Cutler. «DNSMOS P.835: A Non-Intrusive Perceptual Objective Speech Quality Metric to Evaluate Noise Suppressors». В: *2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2022, с. 886—890. DOI: 10.1109/ICASSP43922.2022.9746108. arXiv: 2110.01763. URL: <https://arxiv.org/abs/2110.01763>.
- [13] Paul Boersma. «Praat, a System for Doing Phonetics by Computer». В: *Glott International* 5.9/10 (2001), с. 341—345. URL: https://www.fon.hum.uva.nl/praat/manual/FAQ/_How_to_cite_Praat.html (дата обр. 23.05.2026).
- [14] Johannes Wagner и др. «Dawn of the Transformer Era in Speech Emotion Recognition: Closing the Valence Gap». В: (2022). arXiv: 2203.07378. URL: <https://arxiv.org/abs/2203.07378>.
- [15] Zhou Wang и др. «Image Quality Assessment: From Error Visibility to Structural Similarity». В: *IEEE Transactions on Image Processing* 13.4 (2004), с. 600—612. DOI: 10.1109/TIP.2003.819861.
- [16] Zhi Li и др. *Toward a Practical Perceptual Video Quality Metric*. 6 июня 2016. URL: <https://techblog.netflix.com/2016/06/toward-practical-perceptual-video.html> (дата обр. 23.05.2026).

- [17] Anish Mittal, Anush Krishna Moorthy и Alan Conrad Bovik. «No-Reference Image Quality Assessment in the Spatial Domain». В: *IEEE Transactions on Image Processing* 21.12 (2012), с. 4695—4708. DOI: 10.1109/TIP.2012.2214050. URL: <https://doi.org/10.1109/TIP.2012.2214050>.
- [18] Haoning Wu и др. «Exploring Video Quality Assessment on User Generated Contents from Aesthetic and Technical Perspectives». В: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023. arXiv: 2211.04894. URL: <https://arxiv.org/abs/2211.04894>.
- [19] Camillo Lugaresi и др. «MediaPipe: A Framework for Building Perception Pipelines». В: (2019). arXiv: 1906.08172. URL: <https://arxiv.org/abs/1906.08172>.
- [20] Brandon Castellano. *PySceneDetect: Python-Based Video Scene Cut/Transition Detection Program and Library*. 2020. URL: <https://github.com/BreakthroughPySceneDetect> (дата обр. 23.05.2026).
- [21] Marti A. Hearst. «TextTiling: Segmenting Text into Multi-Paragraph Subtopic Passages». В: *Computational Linguistics* 23.1 (1997), с. 33—64. URL: <https://aclanthology.org/J97-1003/> (дата обр. 23.05.2026).
- [22] Lucas Ventura и др. «Chapter-Llama: Efficient Chaptering in Hour-Long Videos with LLMs». В: (2025). arXiv: 2504.00072. URL: <https://arxiv.org/abs/2504.00072>.
- [23] John Sweller. «Cognitive Load During Problem Solving: Effects on Learning». В: *Cognitive Science* 12.2 (1988), с. 257—285. DOI: 10.1207/s15516709cog12024.
- [24] Richard E. Mayer. *Multimedia Learning*. 2-е изд. New York: Cambridge University Press, 2009.
- [25] Richard J. Riding. «On the Nature of Cognitive Style». В: *Educational Psychology* 17.1–2 (1997), с. 29—49. DOI: 10.1080/0144341970170102.
- [26] Harold Pashler и др. «Learning Styles: Concepts and Evidence». В: *Psychological Science in the Public Interest* 9.3 (2008), с. 105—119. DOI: 10.1111/j.1539-6053.2009.01038.x.

- [27] Carl Gustav Jung. *Psychologische Typen*. Russian translation: *Психологические типы*, 1995. Zürich: Rascher Verlag, 1921. URL: https://archive.org/details/Psychologische_Typen (дата обр. 23.05.2026).
- [28] Isabel Briggs Myers и др. *MBTI Manual: A Guide to the Development and Use of the Myers-Briggs Type Indicator*. 3-е изд. Palo Alto, CA: Consulting Psychologists Press, 1998. ISBN: 0891061304.
- [29] Paul T. Costa и Robert R. McCrae. *Revised NEO Personality Inventory (NEO-PI-R) and NEO Five-Factor Inventory (NEO-FFI) Professional Manual*. Odessa, FL: Psychological Assessment Resources, 1992.
- [30] David J. Pittenger. «Measuring the MBTI... and Coming Up Short». В: *Journal of Career Planning and Employment* 54.1 (1993), с. 48—52.
- [31] Alec Radford и др. «Robust Speech Recognition via Large-Scale Weak Supervision». В: (2022). arXiv: 2212.04356. URL: <https://arxiv.org/abs/2212.04356>.
- [32] OpenAI. *Whisper large-v3-turbo*. 2024. URL: <https://huggingface.co/openai/whisper-large-v3-turbo>.
- [33] Sanchit Gandhi, Patrick von Platen и Alexander M. Rush. «Distil-Whisper: Robust Knowledge Distillation via Large-Scale Pseudo Labelling». В: (2023). arXiv: 2311.00430. URL: <https://arxiv.org/abs/2311.00430>.
- [34] SYSTRAN. *faster-whisper: Faster Whisper transcription with CTranslate2*. 2022. URL: <https://github.com/SYSTRAN/faster-whisper>.
- [35] Michael Chinen и др. «ViSQOL v3: An Open Source Production Ready Objective Speech and Audio Metric». В: *2020 Twelfth International Conference on Quality of Multimedia Experience (QoMEX)*. IEEE, 2020, с. 1—6. DOI: 10.1109/QoMEX48832.2020.9123150. arXiv: 2004.09584. URL: <https://arxiv.org/abs/2004.09584>.
- [36] Silero Team. *Silero VAD: Pre-Trained Enterprise-Grade Voice Activity Detector*. 2021. URL: <https://github.com/snakers4/silero-vad> (дата обр. 23.05.2026).

- [37] International Telecommunication Union. *Recommendation ITU-R BS.1770: Algorithms to measure audio programme loudness and true-peak audio level*. 2023. URL: <https://www.itu.int/rec/R-REC-BS.1770> (дата обр. 27.05.2026).
- [38] Christian J. Steinmetz. *pyloudnorm: A simple yet flexible loudness meter in Python*. 2018. URL: <https://github.com/csteinmetz1/pyloudnorm> (дата обр. 27.05.2026).
- [39] J. L. Pech-Pacheco и др. «Diatom Autofocusing in Brightfield Microscopy: A Comparative Study». В: *Proceedings of the 15th International Conference on Pattern Recognition (ICPR)*. Т. 3. IEEE, 2000, с. 314—317. DOI: 10.1109/ICPR.2000.903548.
- [40] Georg Martius. *vid.stab: Video Stabilization Library*. 2013. URL: <https://github.com/georgmartius/vid.stab> (дата обр. 27.05.2026).
- [41] Ao Wang и др. «YOLOE: Real-Time Seeing Anything». В: (2025). arXiv: 2503.07465. URL: <https://arxiv.org/abs/2503.07465>.
- [42] DeepSeek-AI. *DeepSeek-V4: Towards Highly Efficient Million-Token Context Intelligence*. Тех. отч. DeepSeek-AI, 2026. URL: <https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro> (дата обр. 23.05.2026).
- [43] Qwen Team. «Qwen3.5-Omni Technical Report». В: (2026). arXiv: 2604.15804. URL: <https://arxiv.org/abs/2604.15804>.
- [44] Qwen Team. «Qwen3-VL Technical Report». В: (2025). arXiv: 2511.21631. URL: <https://arxiv.org/abs/2511.21631>.