

Санкт–Петербургский государственный университет

ДРУЖИНИН Максим Александрович

Выпускная квалификационная работа

***Каскад моделей для оценки качества аудио-визуального
образовательного контента и создания рекомендаций по
его улучшению***

Уровень образования: бакалавриат

Направление 02.03.01 «Математика и компьютерные науки»

Основная образовательная программа СВ.5189.2022 «Науки о данных»

Научный руководитель:

научный сотрудник, Лаборатория искусственного
интеллекта, математики и компьютерных наук им.

А. А. Маркова,

к.ф.-м.н. Николаев Максим Сергеевич

Рецензент:

доцент, Национальный исследовательский ядер-
ный университет «МИФИ»,

к.ф.-м.н. Кирова Валерия Орлановна

Санкт-Петербург

2026 г.

Содержание

Введение	3
Глава 1. Анализ предметной области и обзор существующих подходов	5
1.1. Особенности образовательного видео как объекта оценки . .	5
1.2. Существующие инструменты и их ограничения	6
1.3. Методы оценки технического аудио-визуального качества . .	8
1.4. Анализ содержания и тематическая сегментация	9
1.5. Управление вниманием и восприятие учебного контента . . .	9
1.6. Выводы и требования к системе	11
Глава 2. Реализация модулей анализа	13
2.1. Транскрипция	13
2.2. Техническое качество	14
2.2.1 Техническое качество аудио	14
2.2.2 Техническое качество видео	17
2.2.3 Агрегация в метрику технического качества	21
2.3. Флаги восприятия	22
2.3.1 Флаг «Аудио Дисбаланс» (Логик)	23
2.3.2 Флаг «Смысловая унылость» (Интуит)	26
2.3.3 Флаг «Эмоциональный дисбаланс» (Эмоция)	28
2.3.4 Флаг «Визуальный шум» (Сенсорик)	31
2.4. Профиль подачи	34
2.5. Нарративная суммаризация	37
2.5.1 Тематическая сегментация	39
2.5.2 Педагогический анализ	41
2.5.3 Нарратив	42
2.6. Метрика соответствия запросу	42
2.7. Пользовательский интерфейс	43
Список литературы	45

Введение

Объём образовательного видеоконтента на открытых платформах растёт быстрее, чем появляются инструменты для его оценки. Пользователь, выбирая между десятками лекций по одной теме, вынужден ориентироваться на лайки, просмотры и удержание, то есть метрики, разработанные для развлекательного контента и оптимизированные под клик, а не под передачу знаний. Создатель, в свою очередь, не получает содержательной обратной связи: что именно в его лекции не работает и для кого.

Ситуация воспроизводит логику «рынка лимонов» [1]: обе стороны действуют в условиях информационной асимметрии. Устойчивых сигналов, позволяющих сопоставить видео с образовательными целями конкретной аудитории, не существует.

Образовательное видео как объект оценки принципиально отличается от развлекательного: длинный таймлайн, высокая смысловая нагрузка, мультимодальность (речь, слайды, жесты), неравномерность интерактивности и критическая зависимость от контекста целевой аудитории. Ни одна из классических платформенных метрик эти характеристики не учитывает.

Существующие инструменты решают смежные задачи: Gemini позволяет суммаризовать видео по ссылке и генерировать таймкоды, StudyFetch — формировать конспекты и флеш-карты. Однако ни один из них не оценивает видео относительно конкретного пользовательского запроса и не даёт интерпретируемой аналитики для принятия решений.

В данной работе предлагается система автоматизированной оценки образовательного видеоконтента, формирующая аналитическую выдачу в зависимости от профиля пользователя: его роли, уровня подготовки, погружённости в тему и цели просмотра. Система оценивает видео по двум осям — форма и содержание, и включает: техническое качество аудио и видео, систему бинарных флагов восприятия на основе типологии Юнга, профиль подачи (академичность и инструментальность), адаптивную нарративную суммаризацию с тематической сегментацией и метрику соответствия запросу. Все оценки формируются без эталонного референса — исключительно на основе анализа самого видео.

Цель работы — разработать инструмент автоматизированной оценки ка-

чества и релевантности образовательного видеоконтента, формирующий интерпретируемую аналитику для обучающихся и авторов контента.

Задачи:

1. Провести обзор существующих подходов к оценке качества аудио-визуального контента и выявить их ограничения применительно к образовательному видео.
2. Разработать структуру каскадного анализа, охватывающего технические, поведенческие и содержательные аспекты.
3. Реализовать модули оценки: технического качества, флагов восприятия, профиля подачи, нарративной суммаризации и метрики соответствия запросу.
4. Разработать пользовательский интерфейс, обеспечивающий интерпретируемое представление результатов анализа.

Глава 1. Анализ предметной области и обзор существующих подходов

1.1 Особенности образовательного видео как объекта оценки

Образовательное видео отличается от развлекательного по ряду характеристик, принципиальных для задачи оценки. Во-первых, средняя продолжительность лекционного контента на порядок превышает длину развлекательного ролика, что усложняет анализ и делает глобальные агрегированные оценки малоинформативными. Во-вторых, контент мультимодален: речь лектора, слайды, жесты и мимика несут смысловую нагрузку одновременно и по-разному влияют на восприятие в зависимости от аудитории. В-третьих, интерактивность распределена неравномерно — зрительская активность концентрируется в отдельных точках видео и не отражает качество остального материала. Наконец, релевантность образовательного видео не является универсальной характеристикой: одна и та же лекция может быть ценной для студента первого курса и бесполезной для практикующего специалиста. Оценка, не учитывающая контекст пользователя, принципиально неполна.

Из этих особенностей следует, что метрики, разработанные для оценки развлекательного контента (удержание, лайки, просмотры, CTR) не применимы к образовательному видео: они оптимизированы под другую цель и не несут содержательной информации о качестве подачи или релевантности материала.

Перечисленные особенности определяют структуру требований к системе оценки. Мультимодальность и длинный таймлайн означают, что оценка должна охватывать несколько каналов одновременно: деградация любого из них на протяжённом видео непосредственно влияет на восприятие. Неравномерность интерактивности и высокая смысловая плотность требуют анализа внутренней организации материала, а не только его поверхностных атрибутов. Из этого следует разбиение на два измерения: **форма** — как материал представлен технически и как лектор его подаёт, и **содержание** — что именно представлено и насколько это соответствует образовательным целям аудитории.

Форма охватывает техническое качество аудио- и видеоряда: чёткость звука, уровень шума, качество изображения, стабильность съёмки. Однако тех-

нического качества недостаточно: два видео с одинаковыми техническими характеристиками могут восприниматься принципиально по-разному в зависимости от стиля подачи лектора — тональности, эмоциональной окраски, характера жестикуляции, степени формальности. Эти элементы управляют вниманием обучающегося и определяют когнитивную нагрузку независимо от содержания. Вопрос о том, как именно формализовать и измерить паттерны подачи, рассматривается в разд. 1.5.

Содержание определяется структурой и логикой изложения: наличием вводных и заключительных элементов, последовательностью и связностью тем, соответствием названия реальному материалу, а также глубиной и актуальностью: уровнем сложности, плотностью материала, необходимыми пресреквизитами. Релевантность при этом не является изолированным свойством видео: она возникает на пересечении содержательных характеристик и профиля конкретного пользователя — его уровня подготовки, погружённости в тему и цели просмотра.

1.2 Существующие инструменты и их ограничения

Автоматическая оценка образовательного видеоконтента в существующих системах сводится преимущественно к двум категориям метрик: технические атрибуты (разрешение, частота кадров, уровень аудио) и тематическая классификация (тема, ключевые концепции, наличие нежелательного контента) [2]. Эти метрики используются платформами для помощи пользователям при выборе контента, однако не затрагивают ни качество подачи, ни педагогическую структуру. В академической литературе предпринимались попытки оценить более глубокие аспекты. Shi и др. [3] исследуют корреляции мультимодальных признаков (аудио, текстовых и визуальных) с субъективными оценками качества лекций на MOOC-платформе, устанавливая что просодические характеристики и кросс-модальные признаки значимо предсказывают воспринимаемое качество и прирост знаний. Pan и др. [4] предлагают мультимодальный классификатор, обученный предсказывать качество преподавания по пяти аспектам (Clarity, Empathy, Classroom Interaction, Technical Management и Time Management) на размеченных записях очных и вебинарных занятий, достигая точности 0.898 на

бинарной классификации. Zhu и др. [2] предлагает иную постановку: модель симулирует студента, «посещает» лекцию, затем сдаёт тест по внешним учебным материалам темы, и качество видео приравнивается к результату этого теста. Объединяет все три подхода базовая установка: задача формулируется как автоматическое вынесение вердикта о качестве видео. При этом VCEval требует внешних учебных материалов по каждой теме, что ограничивает применимость к произвольному контенту, а Shi и др. [3] и Pan и др. [4] требуют размеченных обучающих данных и плохо переносятся на новые домены и форматы подачи.

Gemini API позволяет взаимодействовать с YouTube-видео напрямую по ссылке и генерировать суммаризации и таймкоды [5]. Недавно анонсированный Ask YouTube расширяет эту функциональность в сторону поиска по личной истории просмотров [6, 7]. Оба инструмента позиционируются как средства работы с контентом в режиме диалога, а не как аналитические системы оценки. Стоимость инференса по YouTube URL через Gemini API может быть существенной при масштабной обработке: видео токенизируется примерно как 300 токенов в секунду, поэтому один час видео даёт около 1.08 млн входных токенов. В зависимости от модели это составляет примерно от \$0.11 за час видео на Gemini 2.5 Flash-Lite до \$2.70+ на Gemini 2.5 Pro, без учёта стоимости выходных токенов [8]. Это ограничивает применимость подхода при массовом анализе YouTube-видео.

Платформы аналогичные StudyFetch больше ориентированы на образование, но решают задачу усвоения уже выбранного материала: генерация конспектов, флеш-карт, тестов [9, 10]. Они включаются после выбора видео и не затрагивают вопрос о том, подходит ли это видео конкретному пользователю.

Поскольку ни один из перечисленных подходов не ставит задачу иначе: предоставить пользователю структурированную интерпретируемую аналитику по нескольким измерениям одновременно (форме, содержанию), чтобы он мог сам принять решение о соответствии видео своим целям. Ниже рассматриваются методологические основы для каждого из них: методы оценки технического качества аудио и видео (разд. 1.3), подходы к анализу содержания и тематической сегментации (разд. 1.4) и психологические функции как инструмент формализации паттернов восприятия (разд. 1.5).

1.3 Методы оценки технического аудио-визуального качества

Качество аудио. Методы оценки качества речевого аудио делятся на intrusive и non-intrusive. Intrusive-методы сравнивают сигнал с эталоном: классический пример — PESQ (Perceptual Evaluation of Speech Quality) [11], стандарт для оценки качества телефонной речи. Такие методы дают точные результаты в контролируемых условиях, но неприменимы к пользовательскому контенту, где эталонная запись отсутствует по определению.

Non-intrusive методы предсказывают воспринимаемое качество непосредственно из сигнала. Среди них выделяется класс перцептивных моделей, обученных имитировать субъективную оценку слушателя по шкале MOS (Mean Opinion Score). Одним из актуальных представителей является DNSMOS P.835 [12], предсказывающая три независимых компонента: качество речевого сигнала, уровень фонового шума и интегральное качество.

Для анализа просодики и характеристик голоса используются инструменты фонетического анализа — в частности, Praat [13], обеспечивающий точное извлечение фундаментальной частоты (F0) и интенсивности. Монотонность речи как характеристика подачи устойчиво коррелирует с низкой вариативностью F0 и громкости [3]. Для оценки эмоциональной окраски речи активно развиваются трансформерные модели [14], которые показывают, что предыдущие подходы систематически занижали точность по валентности, и предлагают архитектуру, закрывающую эту нишу.

Качество видео. No-reference оценка качества видео — активная область исследований, особенно применительно к пользовательскому контенту (UGC). Reference-based метрики, такие как Peak Signal-to-Noise Ratio (PSNR), Structural Similarity Index Measure (SSIM) [15] и VMAF [16] показывают высокую точность в задачах сжатия и стриминга, где оригинальный сигнал доступен, однако неприменимы к оценке снятого пользователем контента без эталона. VMAF, в частности, активно используется Netflix для контроля качества трансляций, но требует оригинального мастер-файла для сравнения.

Классические no-reference подходы, такие как BRISQUE [17], работают на уровне отдельных кадров и оценивают резкость и артефакты в пространствен-

ной области. Более современные модели, например DOVER [18], рассматривают видео целиком и разделяют техническую и эстетическую составляющие качества, что актуально для контента с неоднородными условиями съёмки.

Отдельный класс задач — анализ визуальной сцены и поведения спикера. Для детектирования и трекинга человека в кадре применяются фреймворки компьютерного зрения реального времени, среди которых MediaPipe [19] обеспечивает надёжное извлечение ключевых точек лица и позы. Обнаружение монтажных переходов решается через детекторы смены сцен [20]. Задача распознавания текста в кадре (на доске или слайдах) решается средствами OCR.

1.4 Анализ содержания и тематическая сегментация

Задача тематической сегментации (разбиение на связные смысловые блоки) длинного текста или транскрипта изучается давно. Классический подход TextTiling [21] основан на лексической когезии: границы тем определяются по падению лексического сходства между соседними окнами текста. Метод интерпретируем и не требует обучения, однако чувствителен к шуму в транскрипте и плохо справляется с плавными тематическими переходами, характерными для лекционного контента.

Нейросетевые подходы на основе эмбедингов улучшают качество сегментации за счёт семантического представления текста, но по-прежнему работают с транскриптом как единственным модальным каналом. LLM-based подходы — в частности, Chapter-Llama [22] — используют языковые модели для одновременной сегментации и именования глав, приближаясь по качеству к авторской разметке на видео с чёткой структурой.

1.5 Управление вниманием и восприятие учебного контента

Установив что стиль подачи влияет на восприятие независимо от содержания, необходимо ответить на методологический вопрос: как его структурировать для измерения? Просто перечислить жесты, тональность, темп речи и эмоциональную окраску недостаточно — неясно ни как их группировать, ни в какую сторону и насколько сильно мерить. Нужна теоретическая база, задающая осмысленную декомпозицию.

Теория когнитивной нагрузки [23] и принципы мультимедийного обучения [24] дают хорошо валидированную основу: как устроена рабочая память, как распределяются когнитивные ресурсы между каналами, какие принципы дизайна снижают экзаменационную нагрузку. Эти фреймворки описывают универсальные механизмы восприятия и остаются актуальными ориентирами в проектировании учебного контента. Однако они отвечают на вопрос «что работает для большинства», и не затрагивают вопрос о том, почему одно и то же видео с одинаковым уровнем сложности вызывает у разных людей принципиально разную реакцию на стиль подачи.

Направление когнитивных стилей Riding [25] и модели стилей обучения (VARK и другие) описывают предпочтительные режимы обработки информации: визуальный, аудиальный, вербальный. Интуиция привлекательная, но последующие исследования показали, что влияние стиля обучения на результат опосредовано множеством других факторов (содержанием, контекстом, мотивацией) и не воспроизводится как самостоятельный эффект [26]. Обучение оказывается слишком комплексным процессом чтобы объяснять его через единственную переменную предпочтений.

Наиболее разработанную теоретическую базу для описания индивидуальных различий в обработке информации предложил Юнг в «Психологических типах» [27]. Он выделил четыре психологические функции: мышление — обработка информации через логику и причинно-следственные связи; ощущение — через конкретный чувственный опыт и детали реальности; интуиция — через паттерны, абстракции и возможности; чувство — через ценности, отношения и личную значимость. Функции попарно противоположны (мышление–чувство, ощущение–интуиция), и у каждого человека одна-две являются доминирующими, определяя какой тип информации воспринимается наиболее естественно, а какой требует дополнительных когнитивных усилий.

Юнговская типология получила широкое практическое применение через адаптации: MBTI [28] стал наиболее массовым инструментом, используемым преимущественно в HR, и модель Big Five [29] с непрерывными чертами личности с высокой надёжностью при повторном тестировании и кросс-культурной воспроизводимостью. Критика типологических инструментов обоснована: по данным Pittenger [30], до 50% людей получают другой MBTI-тип при повторном

тестировании через пять недель. Важно, однако, что критика бьёт по инструменту классификации, а не по исходному юнговскому наблюдению о различиях в доминирующих функциях.

Для настоящей работы типологический инструментарий не применяется по прямому назначению: мы не определяем психологический тип зрителя. Четыре юнговские функции используются как теоретическая рамка для структурированной декомпозиции понятия «управление вниманием»: каждая функция описывает режим обработки информации, нарушение которого создаёт специфический тип когнитивного напряжения. Это позволяет перейти от бесструктурного перечня свойств подачи к осмысленной группировке детектируемых паттернов.

1.6 Выводы и требования к системе

Методы оценки технического качества (разд. 1.3) предоставляют надёжные non-intrusive инструменты для анализа аудио- и видеоканала пользовательского контента без эталонного референса. Они дают сигнал на уровне физической воспринимаемости, но не объясняют что именно в подаче создаёт или снижает воспринимаемое качество.

Подходы к анализу содержания (разд. 1.4) работают со структурой транскрипта и семантическими переходами, но не учитывают техническую форму и пользовательский контекст. Академические работы по автоматической оценке образовательных видео [3, 4, 2] формулируют задачу как получение итоговой оценки качества; постановка «интерпретируемая аналитика под профиль пользователя» в литературе не встречается.

Анализ индивидуальных различий восприятия (разд. 1.5) показывает, что стиль подачи не сводится к набору отдельных признаков — для его анализа нужна структурирующая рамка. Юнговские функции рассматриваются в данной работе не как инструмент типирования зрителя, а как основа для группировки паттернов подачи, создающих когнитивное трение.

Совокупность рассмотренных направлений не закрывает ни одного из следующих пробелов:

- интеграция технического качества, содержания и паттернов восприятия в

единую выдачу;

- учёт пользовательского контекста (роли, уровня подготовки и цели просмотра) на всех уровнях анализа, а не как постобработка готового балла;
- интерпретируемая декомпозиция по измерениям вместо единого счёта;
- рассмотрение релевантности как функции пары «видео × пользователь», а не абсолютного свойства контента;
- локализация сигналов по таймкодам.

Эти пробелы непосредственно определяют требования к системе: мультимодальный каскадный анализ с разделением формы и содержания на уровне модулей; no-reference архитектура без дообучения собственных моделей; пользовательский контекст как параметр, пронизывающий все слои, а не применяемый в конце; выдача, структурированная по измерениям и допускающая содержательную интерпретацию каждого компонента.

Перечисленные требования определяют архитектуру системы, описанную в ??.

Глава 2. Реализация модулей анализа

2.1 Транскрипция

Транскрипт является важным ресурсом для большинства слоев. Он потребляется модулями оценки качества аудио, флагов восприятия, профиля подачи и нарративной суммаризации.

В качестве источника транскрипта выбрана модель Whisper [31], а не автоматические субтитры платформы. Принципиальное преимущество такого подхода независимость от источника контента: Whisper принимает на вход произвольный аудиопоток и не предполагает никакой привязки к конкретной платформе. Поскольку Whisper принимает на вход аудиофайл, а не платформенный URL, модуль транскрипции не зависит от источника контента, то есть при смене платформы достаточно заменить только шаг скачивания через `ut-dlp`, всё остальное продолжает работать без изменений. Второе преимущество — контроль над качеством транскрипции: выбор размера модели, параметров инференса и постобработок полностью находится на стороне разработчика, тогда как платформенные субтитры предоставляются «как есть» без возможности влияния на них.

Образовательный контент предъявляет к транскрипции повышенные требования: лекции содержат специализированную терминологию, формулы, и аббревиатуры, которые хуже распознаются компактными моделями. По этой причине используется вариант `large` — крупнейший из доступных, обеспечивающий наилучшее покрытие предметной лексики. При этом применяется дистиллированная версия `large-v3-turbo` [32], разработанная на основе методологии `Distil-Whisper` [33], которая существенно ускоряет инференс при ограниченной деградации точности.

Транскрипция реализована через библиотеку `faster-whisper` [34] — реализацию Whisper на базе `CTranslate2`, обеспечивающую более быстрый инференс по сравнению с оригинальной имплементацией без изменения логики работы модели. Параметр `condition_on_previous_text=False` выключает авторегрессионное «сглаживание» транскрипта, то есть модель реже исправляет слова-паразиты и просторечия, что важно для последующего анализа стиля

речи.

На выходе модуль возвращает список сегментов с текстом и временными метками (start, end в секундах), полный текст транскрипта, длительность и WPM, причем по речевым сегментам, а не по полной длине видео. $[WPM = N_{\text{words}} / (T_{\text{speech}} / 60)]$

2.2 Техническое качество

2.2.1 Техническое качество аудио

Оценка качества аудио строится на двух уровнях: перцептивном и техническом. На выходе модуль возвращает нормированный скор от 0 до 10 и список выявленных проблем (issues).

Перцептивная оценка: DNSMOS. Базой служит DNSMOS P.835 [12] — по-reference перцептивная модель Microsoft, предсказывающая воспринимаемое качество речи без эталонного референса. Модель возвращает три компонента: разборчивость речевого сигнала (sig_mos), уровень фонового шума (bak_mos) и интегральное качество (ovrl_mos). Разложение на компоненты позволяет локализовать природу проблем: низкий bak указывает на шум окружения, низкий sig — на проблемы с голосом.

Из рассмотренных non-intrusive подходов DNSMOS выбрана потому что она обучена специфически на речи, а не на общем аудио, что делает её более надёжной на лекционном материале с фоновым шумом аудитории, эхом и реверберацией. Альтернативная модель ViSQOL [35], кроме того что является reference моделью, так ещё и возвращает единый балл, не позволяющий определить источник проблем.

Компоненты DNSMOS агрегируются во взвешенный показатель с акцентом на общее качество и разборчивость речи:

$$d = 0.50 \cdot \text{ovrl} + 0.35 \cdot \text{sig} + 0.15 \cdot \text{bak}. \quad (1)$$

DNSMOS возвращает значения по шкале от 1 до 5, однако для итоговой метрики системы показатель переводится в шкалу 0–10, что повышает удобство

интерпретации и позволяет согласовать аудио-оценку с остальными компонентами пайплайна. Поэтому взвешенный показатель переводится в итоговую шкалу через сигмоидальное преобразование:

$$base = \sigma(d, c=2.8, k=3) \times 10. \quad (2)$$

Центр сигмоиды выбран равным 2.8, то есть немного ниже теоретической середины шкалы DNSMOS. Такое смещение отражает эмпирическое наблюдение на валидационной выборке: лекционные записи среднего воспринимаемого качества часто получают DNSMOS ниже формальной середины шкалы. Поэтому центр 2.8 позволяет лучше разделять средние и хорошие записи, не завышая итоговые оценки для явно проблемного аудио.

Технические метрики и препроцессинг. Перед техническим анализом аудио разбивается на речевые сегменты и паузы через silero-VAD [36] — лёгкую нейросетевую модель. SNR вычисляется как отношение RMS речевых сегментов к RMS пауз: этот подход не требует отдельной модели шумоподавления и даёт стабильные результаты на лекционном аудио. Громкость оценивается как LUFS через `ryloudnorm` — перцептивно взвешенный стандарт вещательного контента, позволяющий сравнивать субъективно воспринимаемую громкость между видео независимо от пиковой амплитуды (ITU-R BS.1770) [37, 38].

Клиппинг детектируется тремя независимыми метриками. Прямая метрика `clipping_ratio` считает долю сэмплов с амплитудой выше порога 0.99. Однако YouTube нормализует аудио при загрузке, поэтому прямой порог по амплитуде оказывается не всегда легко интерпретируемым: видео с реальными проблемами динамического диапазона в исходной записи (зажатые верхи, перегруженный микрофон) после нормализации могут иметь допустимую пиковую амплитуду. Для устойчивого обнаружения добавлены две формозависимые метрики: `crest_factor` (отношение пика к RMS, так как у клипированного сигнала пики срезаны, поэтому crest factor аномально мал даже после нормализации) и `flattened_peaks_ratio` (доля плоских участков на пиках является прямым признаком формы «срезанной верхушки», который сохраняется при любом масштабировании амплитуды).

Агрегация аудио сора. Технические метрики применяются как мультипликативные штрафы к базовому DNSMOS скору. Мультипликативная схема выбрана потому что деградации накапливаются: одновременно плохой SNR и клиппинг дают более тяжёлый результат, чем каждая из проблем в отдельности. Каждая техническая метрика переводится в штрафной коэффициент $k_i \in [0, 1]$. Чтобы совокупность мелких недостатков не обрушивала скор диспропорционально, суммарный штраф ограничен снизу: $mult = \max(0.60, \prod k_i)$.

Помимо штрафов, применяются условные потолки. Некоторые проблемы принципиально ограничивают воспринимаемое качество и не компенсируются никакими другими метриками: сильный клиппинг означает физическое искажение речи, а очень низкий SNR делает понимание речи затруднённым вне зависимости от остального. В таких случаях итоговый скор не может превысить заданный потолок. Конкретные пороги штрафов и потолков подобраны эмпирически на валидационной выборке.

Финальный аудио скор:

$$audio_score = \max(0.5, \min(ceiling, base \times mult)) \quad (3)$$

где $mult = \max(0.60, \prod k_i)$ — совокупный штрафной коэффициент, $ceiling$ — условный потолок (10 при отсутствии критических проблем), ограничение снизу 0.5 исключает нулевые оценки при частичных данных.

Компонент	Что входит	Роль
<i>base</i>	DNSMOS через сигмоиду	основа
<i>mult</i>	$k_{clipping} \cdot k_{SNR} \cdot k_{LUFS}$	штраф, ≥ 0.60
<i>ceiling</i>	min по clipping и SNR	жёсткий потолок

Таблица 1: Компоненты агрегации аудио сора

Помимо сора, модуль возвращает список выявленных проблем (*issues*) с указанием метрики и уровня критичности — они используются в пользовательском интерфейсе для потенциального содержательного объяснения оценки.

2.2.2 Техническое качество видео

Оценка качества видео построена по той же логике что и аудио: перцептивная модель даёт базовый скор, интерпретируемые метрики применяются как мультипликативные штрафы, образовательно-специфичные компоненты могут как снижать так и повышать итоговый результат. На выходе модуль возвращает нормированный видео скор от 0 до 10 и список выявленных проблем (*issues*).

Извлечение кадров. Видеопоток скачивается в формате H.264 (ограничение 1080p), метаданные (разрешение, FPS, битрейт, кодек) извлекаются через *ffprobe*. Дальнейший анализ работает с двумя наборами кадров. Кадры качества извлекаются с частотой 0.1 fps через *ffmpeg* — одного кадра на десять секунд достаточно для оценки статических характеристик (резкость, экспозиция, контраст, артефакты) при существенном снижении вычислительной нагрузки. Отдельный набор кадров с более высокой частотой используется для анализа мерцания, где важна временная динамика между соседними кадрами.

Перцептивная оценка: DOVER. Базой служит DOVER [18] — no-reference модель, обученная на UGC-датасетах и оценивающая видео с технической и эстетической точек зрения одновременно. Модель возвращает единый *fused score* от 0 до 1. Из доступных no-reference подходов DOVER выбран потому что он обучен специфически на пользовательском контенте (а не на студийных записях), что соответствует природе лекционного видео с неоднородными условиями съёмки.

Как и в случае аудио, скор переводится в шкалу 0–10 через сигмоиду; параметры (центр 0.4, крутизна 10) подобраны эмпирически. Для локализации природы проблем применяются интерпретируемые метрики ниже.

Артефакты сжатия: BRISQUE. BRISQUE [17] оценивает отклонение от статистики естественных сцен — компрессионные артефакты, блочность и зерно нарушают это распределение.

Однако, в итоговую агрегацию не включён. По результатам тестирования метрика не показала устойчивой корреляции ни с субъективным восприятием

качества, ни с другими метриками модуля. Например, видео с белой доской и слайдами систематически получали высокий скор — однородный белый фон с текстом интерпретируется как артефакт компрессии. На тестовой выборке такие видео получали медианный BRISQUE (по шкале 0-100, где меньше - лучше) около 99 при объективно приемлемом качестве. Она сохраняется в raw-выдаче для диагностических внутренних целей и потенциальных будущих улучшений.

Детальные метрики. *Резкость* оценивается через дисперсию Лапласиана [39]. Для агрегации используется 10-й перцентиль по всем кадрам, а не медиана: наихудшие 10% кадров значимее для воспринимаемого качества, чем типичный кадр.

Экспозиция анализируется по V-каналу в HSV-пространстве: вычисляются средняя яркость, доля пересвеченных и недосвеченных пикселей. *Контраст* оценивается как стандартное отклонение яркости в рамках кадра. *Мерцание* — как средняя попиксельная разница яркости между соседними кадрами. Потенциальный источник такого рода искажений, например, флуоресцентные лампы встречающиеся в записях лекций вузов.

Стабильность оценивается через фильтр `vidstabdetect` библиотеки `vid.stab` [40], интегрированной в `ffmpeg`. Алгоритм строится на `feature matching` и оценке глобальной трансформации между кадрами, а результат это среднее смещение в пикселях. Выбор `vidstabdetect` над альтернативами (оптический поток Лукаса-Канаде, попиксельная разница) обусловлен тем, что он оценивает именно движение камеры, а не суммарное движение в кадре включая спикера.

Временная консистентность отражает равномерность условий съёмки на протяжении видео: вычисляется относительное стандартное отклонение резкости и яркости по всем кадрам. Высокая консистентность указывает на стабильные условия съёмки, а резкие выбросы — на смену освещения или перефокусировку.

Образовательно-специфичные метрики. Два компонента специфичны для образовательного формата и не являются метриками качества видео в общем случае.

Видимость спикера отслеживается через `MediaPipe` [19] (модель `blaze_face_f`

Вычисляются доля кадров с обнаруженным лицом и медианный размер лица как доля площади кадра. Эти признаки сохраняются как диагностические, но не входят напрямую в итоговый video score: отсутствие спикера в кадре не всегда является дефектом образовательного видео, поскольку скринкасты, анимированные объяснения и записи работы с доской могут быть полностью валидными без визуального присутствия лектора. Тем не менее для авторов контента такая информация может использоваться как рекомендация по улучшению визуального контакта с аудиторией.

Читаемость доски или экрана оценивается в три слоя. Сначала YOLOE [41] детектирует наличие доски или экрана и возвращает сегментационную маску. По маске OpenCV вычисляет засветку (доля ярких пикселей) и контраст текста.

Наконец, Qwen3-VL-Plus оценивает читаемость по пятибалльной шкале на пяти равномерно распределённых кадрах — модель определяет тип поверхности (физическая доска, маркерная доска, проектор) и формулирует конкретные проблемы. Семантическая оценка через VLM необходима потому что читаемость текста не сводится к контрасту и засветке: рукописные формулы, угол съёмки и качество маркера не улавливаются классическими CV-дескрипторами. Промпт сформулирован так, чтобы оценивать исключительно физические условия восприятия контента на носителе: равномерность и качество освещения, контраст между контентом и фоном, чёткость и размер элементов относительно камеры. Модель явно инструктирована не оценивать язык, почерк, тип контента или временное перекрытие спикером — неровный, но контрастный почерк соответствует уровню 4–5. Такая формулировка делает оценку независимой от предметной области и типа носителя: классная доска, маркерная доска, проекционный экран и планшет оцениваются по одной шкале. Модель возвращает `readability_level` (1–5), `readability_score` (0–1), тип поверхности (`surface_type`) и главные проблемы (`main_issues`). По пяти кадрам агрегируется медиана уровня и среднее сора.


Шкала 1–5 снабжена якорными описаниями для каждого уровня:

1. Засветка или тень физически уничтожают контент;
2. Значительная часть контента теряется;


3. Общая картина понятна, детали теряются;
4. Контент воспринимается без затруднений, незначительные проблемы;
5. Равномерное освещение, высокий контраст, всё чётко различимо.

Якорные описания оказались необходимы: без них модель либо систематически занижала оценки, интерпретируя любые несовершенства как серьёзные проблемы, либо завышала, не понимая что именно является критерием оценки. Дискретная шкала с якорными описаниями используется далее и в текстовых LLM-модулях, так как показала свою эффективность и там: LLM надёжнее выполняет категориальные суждения с опорой на якоря, чем присваивает абсолютные числа в непрерывном диапазоне.

В качестве примера, уровень 3 может достигаться принципиально разными причинами — что иллюстрирует рис. 1.



(a) Меловая доска



(b) Проекционный экран

	(a) Меловая доска	(b) Проекционный экран
surface_type	blackboard	screen
readability_level	3	3
main_issues	partial_obscuration, faint_writing, smudges	glare, smudges, overexposure
Интерпретация	Доска плохо стёрта, часть записей плохо различима.	Артефакты от экрана проектора и камеры, при этом текст читаем.

Рис. 1: Два примера с `readability_level = 3`: одинаковый скор при разных причинах ухудшения читаемости. Левый кадр — меловая доска (МГУ, лекция по мат. анализу), правый — проекционный экран (TED-style лекция на открытой площадке).

Агрегация видео сора. База — DOVER-скор через сигмоиду (центр 0.4, параметры подобраны эмпирически). Четыре метрики применяются как мульти-

пликативные штрафы: резкость (*blur*), мерцание (*flicker*), стабильность (*stability*) и временная консистентность (*consistency*) (высокое стандартное отклонение резкости по кадрам). Каждая метрика переводится в штрафной коэффициент $k_i \in [0, 1]$ и при этом суммарный штраф ограничен: $mult = \max(0.60, \prod k_i)$.

Читаемость доски добавляется аддитивно, а не мультипликативно. Логика: штрафы за резкость, мерцание и стабильность относятся к техническому качеству съёмки — они ухудшают сигнал. Доска же является содержательным элементом: её читаемость не связана с качеством съёмки, но напрямую влияет на образовательную ценность видео. Аддитивная дельта от -1.0 до $+1.5$ отражает этот вклад отдельно от технической составляющей.

Для трёх критических дефектов дополнительно применяются условные потолки: сильное размытие, сильное мерцание или выраженная нестабильность принципиально ограничивают воспринимаемое качество, и никакие другие характеристики это не компенсируют.

$$video_score = \max(0.5, \min(ceiling, base \times mult + board_delta)) \quad (4)$$

Компонент	Что входит	Роль
<i>base</i>	DOVER через сигмоиду	основа
<i>mult</i>	$k_{blur} \cdot k_{flicker} \cdot k_{stability} \cdot k_{consistency}$	штраф, ≥ 0.60
<i>board_delta</i>	читаемость доски (Qwen3-VL, 1–5)	бонус/малус, $[-1.0, +1.5]$
<i>ceiling</i>	min по blur, flicker, stability	жёсткий потолок

Таблица 2: Компоненты агрегации видео сора

2.2.3 Агрегация в метрику технического качества

Итоговый скор технического качества объединяет аудио и видео оценки через гармоническое среднее:

$$technical_score = \frac{2 \times audio_score \times video_score}{audio_score + video_score} \quad (5)$$

Гармоническое среднее выбрано намеренно: оно автоматически штрафует асимметрию между компонентами. Арифметическое среднее видео 8/10 и

аудио 2/10 даёт 5.0 — результат, не отражающий реальное качество просмотра. Гармоническое среднее тех же значений даёт 3.2. Логика та же что и в F1-мере в задачах *information retrieval*, где гармоническое среднее *precision* и *recall* штрафует модели с сильным дисбалансом между ними: лекция с великолепным видео но нечитаемым звуком остаётся плохой лекцией.

В табл. 3 приведены примеры из валидационной выборки, иллюстрирующие разные сценарии соотношения аудио- и видеооценок.

Сценарий	Аудио	Видео	Итог
Студийная запись урока с высоким качеством видео	6.8	9.1	7.8
Хорошая запись вузовской лекции	7.8	7.7	7.75
Запись преподавателя онлайн-школы с хорошим аудио	8.1	5.3	6.4
Старая запись того же канала со слабым видео	7.3	4.3	5.4
Вузовская лекция со слабым аудио при приемлемом видео	4.0	6.7	4.9
Старая запись вузовской практики с низким качеством обоих каналов	0.5	0.6	0.5

Таблица 3: Примеры агрегации аудио- и видеооценок через гармоническое среднее. Таблица показывает, что итоговый технический скор снижается при дисбалансе между каналами: при слабом аудио или видео итог оказывается ближе к худшему компоненту, чем к лучшему.

2.3 Флаги восприятия

В разд. 1.5 юнговские психологические функции были обоснованы как теоретическая рамка для декомпозиции понятия «управление вниманием»: каждая функция описывает доминирующий режим обработки информации, нарушение которого создаёт специфический тип когнитивного напряжения. Здесь эта рамка операционализируется в четыре детектируемых флага (по одному на каждую функцию). Флаг — это бинарный сигнал с параметром уверенности (*confidence*, 0.0–1.0), фиксирующий наличие системной проблемы подачи. Флаги не взаимоисключающие и несколько из них могут сработать одновременно.

Важно что флаги описывают свойства подачи спикера, а не его типа или тип зрителя. Каждый флаг детектирует нарушение доминирующего канала конкретной функции — паттерн в поведении лектора, который создаёт когнитивное

напряжение для людей с данной ориентацией восприятия. В пользовательском интерфейсе флаги названы иначе, чем юнговские типы: пользователь видит содержательное описание проблемы, а не психологическую категорию, чтобы исключить ассоциацию с типированием аудитории и упростить взаимодействие.

Перенос типологии из психологической среды в образовательную нетривиален, так как Юнг формализует сами психологические функции, но не какие именно свойства лекционного видео создают дискомфорт для каждой из них. Для прояснения этих тонкостей был проведён неформальный опрос в сообществе людей из образовательной среды, применяющих психологические теории в собственной педагогической практике. Формат был намеренно неструктурированным, так как цель состояла в сборе мнений о том, что реально выбивает разных людей при просмотре лекций, а не в получении стандартизированных ответов — такие вещи плохо поддаются формализованным анкетам. Опрос позволил откалибровать соответствие между паттернами подачи и тем что действительно создаёт дискомфорт для каждой функции, и в итоге сформировать набор детектируемых паттернов для каждого флага.

Технически флаги неоднородны: часть паттернов детектируется сигнальными методами — акустическими метриками, компьютерным зрением, анализом движения. Часть требует понимания смысла: наличие образности в изложении, характер промежуточных итогов, соответствие эмоционального тона контексту — классические NLP-методы здесь недостаточны, что будет показано в следующих разделах. Для таких задач применяется LLM или VLM в формате структурированных промптов. Во всех флагах, в качестве LLM, используется DeepSeek V4 [42] в разных модификациях: модель выбрана за сильные reasoning-способности, надёжную работу с русскоязычным текстом и стоимость инференса.

2.3.1 Флаг «Аудио Дисбаланс» (Логик)

Логический тип воспринимает информацию преимущественно через аудиальный канал, то есть когда речь или звук мешает восприятию (фоновые шумы, тембральные особенности, слова-паразиты и просторечия) повышается когнитивная нагрузка. Флаг детектирует два класса проблем: техническую деграда-

цию звука и речевые паттерны, создающие когнитивную нагрузку при прослушивании. Компоненты независимы и объединяются через дизъюнкцию — флаг срабатывает если сработал хотя бы один.

Стоит сказать, что Логик по своей природе системен и последователен, то есть хаотичное повествование создаёт для него дополнительную нагрузку. Однако структурность изложения является базовым ожиданием от образовательного контента вне зависимости от типа зрителя, поэтому она не включена в этот флаг как специфичный сигнал и косвенно рассматривается в рамках педагогического анализа нарративного модуля (разд. 2.5).

Аудио-компонент. Технические метрики звука уже вычислены модулем аудио-качества (разд. 2.2.1). Флаг срабатывает, если `audio_score < 5.0`. Этот порог следует из конструкции самой аудио-метрики: `audio_score` нормирован на шкалу 0–10, где значение 5 соответствует границе между условно приемлемым и проблемным качеством речевого канала. На валидационной выборке такая граница дополнительно проверялась как разумный порог срабатывания флага. При срабатывании аудио-компонента `confidence` фиксируется на уровне 0.95: технические метрики дают детерминированный сигнал.

LLM-компонент: речевые паттерны. Второй класс проблем — слова-паразиты и нелитературная речь. Оба явления не поддаются надёжной детекции словарными методами: паразиты разнообразны и контекстно-зависимы, нелитературные формы могут быть намеренной авторской интонацией. Из-за этого компонент построен как проверка устойчивых речевых паттернов, а не как поиск любых отклонений в устной речи. Модель LLM анализирует два критерия: слова-паразиты и нелитературные формы речи, различая нормальные особенности живого объяснения и повторяющиеся элементы, которые начинают мешать восприятию. Для каждого критерия введена трёхуровневая шкала: *clean*, *natural*, *excessive*; флаг срабатывает только при *excessive*. Для снижения ложных срабатываний в промпте явно указано не учитывать единичные оговорки, техническую терминологию, разговорный стиль подачи и артефакты сегментации Whisper на границах фраз. Ответ возвращается в структурированном JSON с уровнем уверенности и короткими цитатами из транскрипта для каждого сра-

ботавшего критерия — это делает срабатывание флага проверяемым.

Детекция артикуляционных дефектов: неудавшиеся подходы. Отдельно исследовалась возможность детектирования артикуляционных особенностей речи (картавость, нестандартный тембр), так как они создают дополнительную когнитивную нагрузку на восприятия для логиков, но не улавливаются транскриптом.

Первая гипотеза состояла в использовании `avg_logprob` Whisper как прокси-метрики уверенности распознавания. Предполагалось, что при нестандартном произношении модель будет менее уверенно декодировать речь, и это отразится в более низком среднем `log-probability`. Однако на тестовых примерах эта метрика не показала устойчивой связи с артикуляционными особенностями: видео без выраженных дефектов речи нередко получали более низкие значения `avg_logprob`, чем видео с заметной картавостью. Вероятная причина состоит в том, что уверенность Whisper сильнее зависит от сложности терминологии, темпа речи, качества записи и локального контекста, чем от самой артикуляционной особенности. Кроме того, модель достаточно робастна к вариативности произношения и часто корректно транскрибирует такую речь, не отражая её нестандартность в значении `avg_logprob`.

Вторая гипотеза состояла в использовании акустических признаков, рассчитываемых в Praat [13]: `jitter`, `shimmer` и `HNR`. Предполагалось, что артикуляционные особенности речи будут отражаться в нестабильности основного тона, амплитуды и гармонической структуры сигнала. Однако на тестовой выборке эти признаки также не дали устойчивого разделения. Так, лектор с выраженной картавостью показал `jitter` 3.17%, тогда как лектор без заметных артикуляционных дефектов — 4.26%. Это показывает, что в условиях естественной YouTube-записи значение признака определяется не только произносительными особенностями, но и шумом, микрофоном, реверберацией, темпом речи и ошибками выделения `voiced`-фрагментов. Вероятная причина заключается в том, что `jitter`, `shimmer` и `HNR` изначально применяются в более контролируемых условиях анализа голоса, тогда как лекционное YouTube-аудио содержит непрерывную речь, фоновые шумы, компрессию и переменное расстояние до микрофона. Поэтому в текущей постановке признаки Praat были признаны недостаточно

устойчивыми для детектирования артикуляционных особенностей.

Финальная гипотеза состояла в использовании Qwen Omni с нативным аудиовходом: тестировались Qwen2.5-Omni-7B локально и Qwen3.5-Omni-Plus через API. Предполагалось, что мультимодальная модель сможет напрямую оценить не только содержание речи, но и особенности её звучания. Однако в тестовых примерах модели возвращали false даже для видео с заметными артикуляционными особенностями. Вероятная причина состоит в том, что аудио-LLM в первую очередь оптимизированы на распознавание и понимание содержания речи, а не на анализ паралингвистических характеристик: тембра, артикуляции, дикции и индивидуальных особенностей произношения.

Поэтому детектирование артикуляционных особенностей было исключено из текущей реализации как отдельная нерешённая подзадача.

2.3.2 Флаг «Смысловая унылость» (Интуит)

Интуитивный тип воспринимает информацию через движение смыслов. Хорошая лекция для него — та, где каждый следующий фрагмент добавляет новый ракурс, поворот или связь: мысль не топчется на месте, а идёт вперёд. Образность и аналогии (переносы понятий из одной предметной области в другую) помогают увидеть предмет объёмно, а не плоско. Промежуточные итоги должны быть синтезом, а не пересказом сказанного. Важно слышать самого лектора: его интерпретацию, взгляд, личный заход на тему, то, чего нет в учебнике и ради чего вообще стоит слушать лекцию, а не читать. Когда этого нет, а лектор механически озвучивает слайды или учебник, интуиту становится скучно вне зависимости от качества звука и картинки.

Промпт и три оси оценки. Флаг анализирует транскрипт по трём осям.

Semantic_dynamics — центральная ось: движется ли мысль вперёд. Каждый следующий фрагмент должен добавлять новое — обобщение, неожиданный ракурс, выход на следующий уровень понимания. Absent ставится только при устойчивом паттерне топтания по всей лекции: лектор переливает воду, дублирует сказанное другими словами, зачитывает то что и так на экране.

Imagery — метафоры, аналогии, переносы понятий из одной области в

другую, образные сравнения. Не считается одно техническое определение или вычисление — речь о том, помогает ли лектор увидеть предмет с разных сторон.

Own_voice — слышен ли сам лектор: его взгляд, интерпретация, личный пример, неожиданный заход на тему. Или содержание можно слово в слово прочитать в любом учебнике.

Каждая ось оценивается по шкале *strong / present / absent*; флаг срабатывает только при *absent*. Модель обязана приводить цитаты из транскрипта — без них вердикт сложно провалидировать. В табл. 4 показано, как три оси оценки работают на примерах лекций с разным стилем подачи.

Флаг сработал <i>БЖД, онлайн-курс</i>	Флаг не сработал <i>Матанализ, онлайн-школа (для студентов)</i>	Флаг не сработал <i>Параметры ЕГЭ, онлайн-школа (для школьников)</i>
s_dyn: absent «Первая группа — процессы преобразования веществ... Вторая группа — процессы создания вещей... Четвёртая группа — процессы разложения.»	s_dyn: strong «Давайте сначала на пальцах это покажем, а потом аккуратно всё докажем.»	s_dyn: strong «Мне нужно разобраться, что с этим уравнением происходит. Начну с самой частой области.»
imagery: absent «Структурными элементами техносферы являются технические изделия и территориально-промышленный комплекс.»	imagery: present «Два милиционера кого-то куда-то ведут.»	imagery: present «Прямая вот так вот будет ездить вверх-вниз.»
own_voice: absent «Продолжаем изучать дисциплину безопасности жизнедеятельности. Продолжаем рассмотрение вопросов первого раздела.»	own_voice: strong «Я даже не знаю, коснулась ли эту теорему реформа полиции...»	own_voice: strong «Дружище, ты должен помнить: параметр — это задача сильнейших.»

Таблица 4: Спектр оценок флага «Смысловая унылость» на трёх лекциях разного стиля. Флаг детектирует отсутствие смысловой динамики и авторского голоса, а не неформальность подачи: академичная лекция и молодёжный курс для школьников одинаково проходят проверку при разном регистре речи. Примеры — цитаты выбранные моделью как иллюстрации вердикта, а не триггеры срабатывания.

Эволюция промпта. Первая версия флага содержала шесть бинарных вопросов: наличие *hook* в первые минуты, метафоры, переформулировки, синтез vs пересказ, авторская позиция, механические отговорки. Флаг срабатывал при двух и более проблемах. Подход оказался хрупким: *hook* нерелевантен для фрагментов длинных курсов, *synthesis_not_summary* давал ложные срабатывания на математических лекциях где пересказ ключевого шага перед следующим

— нормальная педагогика. Переход к трём осям с асимметричной агрегацией устранил эти проблемы: вместо чеклиста критериев модель оценивает целостные характеристики подачи.

Агрегация. Агрегация асимметрична: `semantic_dynamics = absent` триггерит флаг самостоятельно — это центральная потребность интуита. `imagery` и `own_voice` работают в паре: если оба `absent`, то лекция является озвучкой учебника, что само по себе достаточно для срабатывания флага.

$$\begin{aligned} flag = & (\text{semantic_dynamics} = \text{absent}) \vee \\ & \vee (\text{imagery} = \text{absent} \wedge \text{own_voice} = \text{absent}) \end{aligned} \quad (6)$$

Дублирование слайдов и OCR. Дублирование слайдов изначально планировалось детектировать отдельным OCR-компонентом. Код был даже реализован, однако не интегрирован: ось `semantic_dynamics` уже улавливает это через семантику транскрипта — на видео где лектор дословно читает слайды LLM стабильно возвращает `absent`. Ко всему прочему OCR покрыл бы только напечатанный текст на экране, а для рукописного контента потребовалась бы VLM, что существенно утяжелило бы модуль. Поскольку семантический подход справился, OCR-компонент остался нереализованным.

2.3.3 Флаг «Эмоциональный дисбаланс» (Эмоция)

Эмоциональный тип всё воспринимает через атмосферу, людей и характер взаимодействия. Из-за этого в лекции они ожидают ровной эмоциональной окраски: монотонный лектор воспринимается как безжизненный и утомляет, излишне напористый или театральный — как давящий и неискренний. Особенно болезненны эмоциональные качели — резкие перепады интенсивности, которые рассинхронизируют восприятие и мешают сосредоточиться.

Arousal как основной сигнал. Модель audEERING [14] предсказывает три измерения эмоционального состояния: `valence`, `arousal` и `dominance`. Для детекции эмоционального дисбаланса используется только `arousal` — он отражает

энергию и вовлечённость речи. Valence отражает позитивность или негативность, что нерелевантно для оценки подачи; dominance мало информативен в лекционном контексте.

Аудио нарезается на окна по 30 секунд, для каждого предсказывается arousal в диапазоне 0–1, итоговый временной ряд описывается mean и std. Флаг срабатывает при трёх условиях:

- *flat* — $\text{std} < 0.05$ или $\text{mean} < 0.30$: монотонная или безжизненная подача;
- *high* — $\text{mean} > 0.75$: слишком высокий эмоциональный напор;
- *volatile* — $\text{std} > 0.15$: резкие эмоциональные перепады.

На рис. 2 показано сравнение двух роликов: спокойной лекции и экспрессивного выступления. Ось X нормирована в проценты длины видео, поэтому сравнение не зависит от разной длительности записей. Пунктирные линии показывают среднее значение arousal, а полупрозрачные области — диапазон $\text{mean} \pm \text{std}$.




Рис. 2: Сравнение динамики arousal для спокойной лекции и экспрессивного выступления. В экспрессивном примере средний arousal находится выше порога *high* ($\text{mean} = 0.838 > 0.75$), поэтому срабатывает флаг эмоционального дисбаланса. В спокойной лекции среднее значение остаётся в нормальной зоне ($\text{mean} = 0.542$), а вариативность невысока ($\text{std} = 0.056$).

Важным эмпирическим наблюдением стало то, что для детекции монотонности стандартное отклонение arousal оказалось информативнее сред-

него значения. Например, лектор, читающий материал с презентации, даёт $\text{std} \approx 0.04$, тогда как у лектора с более живой подачей значение составляет около $\text{std} \approx 0.07$. При этом среднее значение arousal в обоих случаях может быть близким, поэтому именно вариативность эмоциональной интенсивности используется как основной сигнал монотонности.


Уверенность confidence вычисляется как нормированное отклонение от «нормальной» зоны ($\text{mean} = 0.5$, $\text{std} = 0.08$): чем дальше от центра по обоим измерениям, тем выше уверенность.

Анализ движения лектора. Анализ движения лектора используется как вспомогательный диагностический слой флага. Для этого рассчитываются два блока признаков: движение центроида плеч, отражающее перемещение лектора в пространстве, и динамика запястий, отражающая жестикуляцию. Анализ выполняется через MediaPipe [19] (модель `pose_landmarker_lite`) в одном проходе по видео.

Центроид (плечи, 1 кадр каждые 3 секунды по всему видео) отражает перемещение лектора в пространстве: `position_range` — горизонтальный диапазон, `velocity_mean` — средняя скорость.

Запястья (5 fps в динамических окнах по 15 секунд) отражают жестикуляцию. Для нейтрализации ложных срабатываний у лекторов которые ходят применяется *damped normalization*: $\text{gesture_ratio} = \text{amplitude_mean} / (0.1 + \text{position_range})$. При неподвижном лекторе знаменатель не вырождается в ноль; при ходячем лекторе у доски ходьба не засчитывается как жестикуляция. Пример работы такой нормировки приведён на рис. 3. Флаг жестикуляции срабатывает при $\text{gesture_ratio} > 1.35$ и $\text{velocity_mean} > 0.07$. Первые и последние 5% видео пропускаются, так как это часто заставки и концовки.

Неудавшийся эксперимент. Тестировался `lift_mean` — среднее вертикальное положение запястий относительно плеч как сигнал эмоциональной жестикуляции (активные жесты смещают руки выше нейтрального положения). На тестовой выборке улучшения не показал и был убран: вертикальное положение рук сильно зависит от ракурса съёмки и позы лектора, а не только от интенсивности жестикуляции.



(a) Перемещение у доски

(b) Жестикуляция на месте

	(a) Перемещение у доски	(b) Жестикуляция на месте
position_range	1.01	0.32
velocity_mean	0.16	0.06
amplitude_mean	1.17	0.59
gesture_ratio	1.05	1.42
gesture_active	false	true
Интерпретация	Лектор активно перемещается у доски. Высокая амплитуда записей объясняется ходьбой и письмом, а не жестикуляцией.	Спикер стоит на месте и активно жестикулирует. Меньшая абсолютная амплитуда при малом position_range даёт отношение выше порога.

Рис. 3: Иллюстрация damped normalization в анализе движения лектора. Крест обозначает центроид плеч, точки — запястья. Нормировка на диапазон перемещения позволяет отделить ходьбу у доски от активной жестикуляции.

2.3.4 Флаг «Визуальный шум» (Сенсорик)

Сенсорный тип воспринимает информацию через визуальный канал и конкретность происходящего в кадре. Визуальный дискомфорт для него возникает когда кадр перегружен раздражителями: неаккуратный фон отвлекает от лектора, перегруженные слайды не дают сосредоточиться на содержании, резкие перемещения лектора между склейками дезориентируют. Флаг агрегирует четыре независимых сигнала через дизъюнкцию.

VLM-анализ визуальной опрятности. Qwen3-VL-Plus оценивает 5 случайно выбранных кадров из видео. Пять кадров используются потому, что фон, внешний вид лектора и общая визуальная организация кадра обычно мало меняются в течение лекции, а анализировать такие признаки каждые 30 секунд вычислительно дороже, но не существенно информативнее. Промпт оценивает только

физические визуальные факторы, игнорируя содержание.


Промпт выделяет три категории визуальных проблем.

- *Untidy* — визуальная неаккуратность среды или лектора:
 - U1 — предметы на фоне расставлены вразнобой и не выровнены;
 - U2 — одежда в беспорядке (расстёгнута, перекошена);
 - U3 — реальный blown-out пересвет (чисто-белые участки без деталей, ореол вокруг головы);
 - U4 — явно лишние объекты (провод через кадр, мусор, порванная штора).
- *Overloaded_slide* — перегрузка слайда:
 - F1 — вычурный фон (космос, насыщенный градиент, сложная текстура);
 - F2 — несколько разнородных картинок;
 - F3 — плотный текст без структуры;
 - F4 и F5 — мешанина цветов и шрифтов.
- *Visual_outburst* — резкий визуальный выброс:
 - V1 — яркий отвлекающий объект в кадре;
 - V2 — экстравагантный образ лектора (только при двух и более маркерах одновременно).

Серьезность проблемы (*severity* 0–3) вычисляется через взвешенное число факторов: *overloaded_slide* весит 1.5, *visual_outburst* — 1.3, *untidy* — 1.0. Для категории *untidy* *severity* снижается на 1 если фон расфокусирован: неаккуратные предметы на боке не мешают восприятию. Флаг VLM срабатывает если не менее двух кадров из пяти имеют $severity \geq 2$.

Примеры на рис. 4 показывают, что VLM-ветка различает допустимое студийное оформление, слабые локальные замечания и устойчивый визуальный шум. Так, отдельные проблемы уровня *severity*=1 сохраняются в выдаче, но не


приводят к срабатыванию флага; флаг зажигается только при повторяющихся проблемах средней или высокой тяжести.




(a) Студийная запись



(b) Лекция у доски с пересветом



(c) Перегруженная презентация



(d) Лекция с артефактами экрана

Пример	VLM-выход	Основная причина
(a) Студийная запись	flag=false issues_ratio=0.0 severity=[1,1,1,1,1]	Студийное оформление: яркий фон и декоративные элементы есть, но они организованы и не мешают восприятию.
(b) Лекция у доски с пересветом	flag=true issues_ratio=0.8 severity=[2,2,2,1,2]	Пересветы и слабые визуальные помехи в области доски и лектора.
(c) Перегруженная презентация	flag=true issues_ratio=1.0 severity=[3,3,2,3,3]	Плохое оформление презентации: плотный текст, вычурный фон и несколько конкурирующих визуальных элементов.
(d) Лекция с артефактами экрана	flag=true issues_ratio=0.6 severity=[3,1,3,1,3]	Слайды содержат артефакты проекционного экрана, а окружающая обстановка создаёт дополнительный визуальный шум.

Рис. 4: Примеры VLM-оценки визуального шума. Флаг срабатывает не при любом замечании модели, а при устойчивых проблемах с $severity \geq 2$ в значимой доле кадров.

Плотность и дёрганость склеек. Склейки детектируются через PySceneDetect [20]. Плотность нормируется по длине видео: более 4 склеек в минуту создаёт дискомфорт независимо от их характера. Первые и последние 30 секунд видео пропускаются — заставки и концовки.

«Дёрганость» в данном контексте имеет такой смысл: лектор между двумя смежными склейками оказывается в принципиально другой части кадра, и зритель вынужден каждый раз заново искать его взглядом. Для детекции таких прыжков сравнивается горизонтальная позиция центра плеч лектора (MediaPipe [19]) до и после каждой склейки: $\text{pose_jump} = |\Delta x|/0.3$, где нормировка на 0.3 такова что прыжок на треть ширины кадра даёт $\text{score} = 1.0$. Пример такой склейки приведён на рис. 5.

Склейка считается дёрганой при $\text{pose_jump} > 0.4$. Такие склейки подсчитываются по всему видео, после чего нормируются по длительности:

$$j_{pm} = \frac{N_{\text{jerk}}}{T/60},$$

где j_{pm} соответствует метрике `jerk_per_minute`. Флаг срабатывает при $j_{pm} > 0.3$, то есть единичный прыжок не наказывается, важна плотность.


Видеоскор и агрегация. Дополнительно переиспользуется `video_score` из модуля видеокачества: оценка ниже 5.0 триггерит флаг независимо от остальных компонентов. Это страховочный сигнал для случаев объективно плохого качества записи, которые VLM или анализ склеек могли пропустить.

Итоговый флаг:

$$\text{sensor_flag} = \text{vlm_flag} \vee \text{cut_density_flag} \vee \text{jerk_flag} \vee \text{video_quality_flag} \quad (7)$$

2.4 Профиль подачи

Профиль подачи описывает глобальную педагогическую ориентацию лекции по двум независимым осям: академичность и инструментальность. Важно, что это не про поверхностные признаки текста (наличие формул, определений или примеров), а скорее про глобальную цель занятия. Лекция по линейной алгебре, например, на экономическом факультете и на математическом фа-



Параметр	Значение и интерпретация
Склейка	#12, момент времени $t = 08:13$
Положение лектора до склейки	$cx = 0.708$
Положение лектора после склейки	$cx = 0.103$
Смещение	$\Delta cx = 0.708 - 0.103 = 0.605$
Нормированный скачок	$pose_jump = \min(\Delta cx / 0.3, 1.0) = 1.0$
Интерпретация	Лектор после склейки оказывается в принципиально другой части кадра. Такое смещение дезориентирует зрителя: взгляд приходится заново переносить в другую область экрана. Поэтому склейка классифицируется как <i>дёрганая</i> .

Рис. 5: Пример расчёта $pose_jump$ для одной склейки. Слева показан кадр непосредственно до склейки, справа — после неё. Крест обозначает центроид плеч лектора, по которому измеряется горизонтальное смещение между соседними сценами.

культете одного и того же вуза могут иметь близкий лексический состав, иметь теоремы и аксиомы, но принципиально разную педагогическую цель — одна объясняет чтобы в дальнейшем применять, другая строит строгую теорию.

Академичность измеряет стремление лекции ответить на вопрос «почему», то есть сформировать теоретическое понимание предмета, а инструментальность — стремление ответить на «как» — развить практическую компетенцию.

Рассмотренные подходы. Первым был протестирован zero-shot NLI: академичность и инструментальность формулировались как гипотезы, модель возвращала вероятности entailment. Результатом является полная сатурация: все видео получили 9.5–10.0 по обеим осям. NLI-модели обучены на формальном

entailment общего характера и не различают педагогические ориентации внутри образовательного дискурса — они фиксируют формальное наличие признаков («в тексте есть определения» значит true), а не глобальную цель занятия.

Следующим подходом был LLM с непрерывной шкалой 0–1. Та же проблема в другом виде: без якорных точек модель не имеет опоры для дифференциации, оценки кластеризовались в узкой зоне.

Выбранный подход. Выбран дискретный пятиуровневый формат с якорными описаниями для каждого уровня. Такой формат снижает неопределённость LLM-оценки: модель не просто выбирает число, а сопоставляет подачу с заранее заданным описанием педагогической ориентации.

Шкала академичности задаётся следующим образом:

1. Разговорное или обзорное объяснение «на пальцах»: почти нет строгих терминов, формального аппарата, теоретической рамки или обоснований.
2. Концептуальное объяснение: термины и идеи присутствуют, но без строгой системы, формальных определений, доказательств или глубокого вывода.
3. Умеренно академическая подача: определения, формулы, понятия или модели вводятся достаточно аккуратно; есть объяснение связей, но теория не строится как строгая система.
4. Строгая академическая подача: есть определения, утверждения, обоснования, доказательства или выводы; цель — понять, почему утверждения верны, и научиться рассуждать строго.
5. Фундаментальная теоретическая подача: предмет строится как система; есть аксиоматика, формальные доказательства, глубокие обобщения, строгая структура понятий; прикладная тренировка минимальна или вторична.

Шкала инструментальности задаётся отдельно:

1. Почти нет применения: видео в основном объясняет, обсуждает или мотивирует, но не учит действовать, решать, считать или применять.

2. Есть отдельные примеры или намёки на применение, но без полноценного разбора метода, задачи, процедуры или результата.
3. Умеренная применимость: есть разбор метода, примеры, ход рассуждения, частичная демонстрация применения или пошаговое объяснение, которое можно повторить.
4. Практико-ориентированная подача: значимая часть видео посвящена задачам, кейсам, вычислениям, алгоритмам, типовым ситуациям, ошибкам или применению метода; зритель понимает, как применять материал.
5. Tutorial / practicum / problem-solving session: главная цель — повторить действия и получить результат; много конкретных шагов, процедур, решений, вычислений, кода, настроек или практических действий.

Внутри каждого уровня модель дополнительно выставляет score от 0.0 до 1.0 как более точную позицию на соответствующей оси. Это даёт непрерывность оценки при сохранении категориальной структуры. После ответа LLM значение score согласуется с выбранным уровнем: каждому уровню соответствует допустимый диапазон, что предотвращает противоречия между категориальной и числовой оценкой.

Полученные значения `academic_score` и `instrumental_score` можно интерпретировать как координаты видео в двумерном пространстве профилей подачи. Примеры на рис. 6 показывают, что эта плоскость разделяет не конкретные предметные области, а педагогическую ориентацию занятия: обзорный формат, научно-популярную лекцию, академическую лекцию, смешанный формат «теория + задачи» и практический разбор.

Оси независимы, так как семинар высокого уровня с теорией и задачами может получить 5 по академичности и 4 по инструментальности одновременно. Модель предоставляет evidence (конкретные цитаты и наблюдения из транскрипта) для каждой оценки для валидации.

2.5 Нарративная суммаризация

Нарративный модуль формирует текстовую выдачу из трёх компонентов: тематическая сегментация с таймкодами, педагогический анализ содержания и



Пример	Интерпретация	
Обзорное видео	научпоп-	Короткий научпоп о препарате для снижения веса: знакомит с темой, но не строит строгую теорию и не обучает действию.
Научпоп-лекция		Популярная лекция о сне: связанное объяснение биологической темы без строгого академического аппарата и tutorial-логики.
Академическая лекция		Вводная лекция по математическому анализу о действительных числах: акцент на понятиях, определениях и структуре дисциплины.
Теория + задачи		Курс подготовки по математическому анализу для сильного экономического факультета: теория сочетается с разбором задач.
Разбор задачи		Математика для сильных школьников: разбор параметрической задачи экзаменационного уровня с акцентом на алгоритм решения.

Рис. 6: Примеры распределения видео в пространстве профилей подачи. Ось X отражает инструментальность, ось Y — академичность. Пунктирные линии при 0.5 разделяют пространство на четыре условные зоны: *поверхностное*, *tutorial*, *лекция-монолог* и *полный курс*.

нарратив. Компоненты взаимосвязаны: сегменты служат основой для педагогического анализа, а анализ питает нарратив.

2.5.1 Тематическая сегментация

Задача — разбить транскрипт на смысловые блоки с названиями и таймкодами. Гранулярность адаптивна: пользователь с целью «составить общее представление» получает крупные блоки, а с целью «последовательно изучить тему» — детальную разбивку каждого подраздела.

Попытка с классическим NLP. Первый подход — эмбединги sentence-transformers и косинусное сходство между соседними чанками: падения сходства должны указывать на границы тем. Результат для одной из лекций показан на рис. 7: впадины действительно присутствуют и соответствуют реальным переходам, однако принципиальная проблема в подборе порогового значения. На разных лекциях (разная тематика, разный стиль подачи, разная плотность материала) оптимальный порог сильно варьируется, и без крупной размеченной выборки нет подходов его выставления.




Рис. 7: Косинусное сходство между соседними чанками лекции. Жёлтые линии — найденные границы тем при пороге 0.625. Проблема: положение красной линии не имеет принципиального обоснования без разметки на большой выборке.

Этот подход остаётся потенциально интересным в рамках оптимизации: комбинация NLP-детекции границ и небольшой LLM только для именования

сегментов позволила бы снизить стоимость и зависимость от API. Аналогичное направление (использование fine-tuned малой LLM для чаптеризации) рассматривается в Chapter-Llama [22]. В текущей реализации задача полностью передана LLM.

LLM-сегментация. Цель просмотра передаётся в промпте явно и управляет гранулярностью сегментации. Для разных сценариев используются разные инструкции:

- *Составить общее представление* — выделяются только крупные смысловые части. Близкие подтемы объединяются, если они служат одной общей идее. Определения, примеры и пояснения не дробятся, если относятся к одному блоку понимания. Описание блока формулируется кратко: что в целом происходит в этой части.
- *Закрыть точечные вопросы* — сегментация становится более детальной. Модель отделяет новые определения, важные примеры, доказательства и переходы к частным вопросам, чтобы пользователь мог по названию и описанию понять, где искать конкретный ответ.
- *Последовательно изучить тему* — выделяются учебные главы среднего размера: подготовка, введение понятий, основные определения, примеры, доказательства и выводы. Модель не дробит лекцию до отдельных реплик, но и не склеивает этапы, которые требуют разного понимания.

При этом число сегментов не задаётся заранее. В промпте отдельно указано, что модель должна учитывать длительность видео, плотность объяснения и реальные тематические переходы: если тема развивается плавно, фрагменты объединяются; если начинается новый учебный шаг, он выделяется отдельно. Таймкоды не генерируются LLM: модель возвращает только `block_id` начала темы, а финальная привязка ко времени берётся из соответствующего Whisper-чанка. Это снижает риск галлюцинации таймкодов и сохраняет точную синхронизацию с исходной транскрипцией.

В табл. 5 показан результат для одной длинной лекции от вуза по математическому анализу при двух разных целях просмотра.

Укрупнённая сегментация	Соответствующие детальные блоки
[00:06] Введение в курс	3 детальных блока: [00:06] Введение в математический анализ [02:51] Кризис основ и новый уровень строгости ... [04:37] Учебная литература и организация курса
[07:43] Теоретико-множественные основы и функции	8 детальных блоков: [07:43] Вспомогательные конструкции: множества и функции ... [24:05] Классификация функций: инъекция, сюръекция, биекция ... [45:47] Законы де Моргана для семейств множеств
[56:40] Аксиомы действительных чисел	4 детальных блока: [56:40] Аксиоматический подход к действительным числам [1:00:29] Аксиомы сложения и умножения ... [1:12:26] Аксиома непрерывности

Таблица 5: Адаптивная тематическая сегментация одной и той же лекции. Слева показаны 3 укрупнённых смысловых блока для цели «*составить общее представление*», справа — фрагменты соответствующей детальной сегментации для цели «*последовательно изучить тему*». Полная детальная разбивка содержит 15 тематических блоков; в таблице для компактности показаны начало и характерные промежуточные элементы каждого крупного блока.

2.5.2 Педагогический анализ

Педагогический анализ выполняется на полном транскрипте с учётом пользовательского контекста (уровень, погружённость, цель просмотра) и включает шесть компонентов.

Таксономия Блума [43] применяется к каждому тематическому сегменту, а не к видео целиком. Один сегмент получает уровень from *remember* до *create*; доминантный уровень по всему видео агрегируется в коде. Разметка по сегментам позволяет видеть неоднородность лекции: введение на уровне *remember*, основная часть на *apply*.

Пресреквизиты возвращаются с уровнем уверенности (high / medium / low); в финальный нарратив включаются только high — модель сама решает что является пресреквизитом для данного уровня пользователя. Пресреквизиты для школьника и для магистра по одному видео будут разными.

Покрывтие темы: topics_covered — что реально разобрано; topics_gaps — что заявлено в названии, но не раскрыто.

Соответствие названия (full / partial / misleading) с однострочным объ-

яснением.

Тип учебного маршрута определяет место видео: введение в тему, часть курса, самостоятельная лекция или продвинутый уровень.

Плотность материала и уникальный подход — низкая/средняя/высокая информационная плотность и одно предложение о том, чем этот лектор выделяется среди других материалов по теме.

2.5.3 Нарратив

Нарратив сильно отличается от суммаризации. Суммаризация отвечает на вопрос «что в видео», а нарратив — «почему это видео ценно именно для этого человека». Задача формулируется как текст от лица человека, который посмотрел видео и понял, в чём его ценность: это не реклама и не пересказ тем, а честная оценка пригодности материала для конкретного пользовательского сценария.

Для этого prompt задаёт два уровня ограничений. Первый уровень — стилевой: взрослый нейтральный тон, без блогерских оборотов, эмоциональных усилителей и прямых призывов смотреть видео. Второй уровень — пользовательский контекст: модель должна писать не универсальную аннотацию, а текст для конкретного адресата с конкретной целью просмотра. Этот контекст собирается из трёх параметров профиля: уровня образования, цели просмотра и погружённости в тему.

Пользовательский контекст отображается в конкретные формулировки для prompt через три словаря; результат конкатенируется в одну строку *social context*, которая передаётся модели вместе с результатами сегментации и педагогического анализа. Отображение приведено в табл. 6.

2.6 Метрика соответствия запросу

Метрика соответствия запросу — интегральная оценка по шкале 0–100, агрегирующая все вычисленные компоненты с учётом пользовательского профиля. Одно и то же видео получает разный балл для школьника и специалиста, для цели «составить общее представление» и «последовательно изучить тему». Дополнительно учитываются метаданные: соответствие названия содержанию

Уровень образования	Адресат в промпте
Школьник	ученику старших классов
Бакалавр (1–2 курс)	студенту младших курсов
Бакалавр (3–4 курс)	студенту бакалавриата
Магистр	студенту магистратуры
Специалист / Профессионал	профессионалу в теме
Цель просмотра	Фрейм ценности
Составить общее представление	которому нужен быстрый обзор содержания
Закреть точечные вопросы	которому важно понять, где разбирается нужная тема
Последовательно изучить тему	который решает, стоит ли смотреть видео целиком
Погружённость	Уточнение
Изучаю с нуля	(только начинает разбираться)
Знаю частично	(немного знаком с темой)
Достаточно погружён	(в теме, просто не смотрел это видео)
Экспертный уровень	(эксперт, интересуется только что нового)

Таблица 6: Отображение пользовательского профиля в формулировки нарративного промпта. Три компонента конкатенируются в одну строку social context.

и наличие у канала связанной серии лекций.

Методология взвешивания компонентов находится в разработке: текущие веса подобраны эмпирически на валидационном датасете и требуют дальнейшей калибровки.

2.7 Пользовательский интерфейс

Интерфейс решает две задачи: минимизировать усилия пользователя на входе и сделать выдачу интерпретируемой без дополнительного контекста.

Выбор четырёх входных параметров был нетривиальным упражнением: хотелось покрыть ключевые сценарии использования при минимальном количестве полей. Итоговый набор — роль, уровень образования, погружённость в тему, цель просмотра — признан минимально достаточным после нескольких итераций.

Поскольку пайплайн ресерческий и занимает несколько минут, пользователю отображаются этапы обработки в реальном времени, включая появление транскрипта по мере его готовности. Важно для ресурсоёмкого процесса, чтобы пользователь понимал что происходит.

На экране результатов пользовательские параметры остаются видны по-

стоянно, а всё остальное интерпретируется относительно них. Метрики интерактивны: при нажатии раскрывается описание и интерпретация применительно к конкретному видео. Флаги реализованы как бинарные индикаторы — числовые шкалы для них не используются, поскольку создавали бы ложное ощущение точности. Профиль подачи визуализирован как спидометр со смещением от центра, что передаёт доминирующую ориентацию нагляднее двух отдельных чисел. Таймкоды в нарративной части кликабельны и переключают встроенный YouTube-плеер на нужный момент.

Список литературы

- [1] George A. Akerlof. «The Market for “Lemons”: Quality Uncertainty and the Market Mechanism». В: *Quarterly Journal of Economics* 84.3 (1970), с. 488—500. DOI: 10.2307/1879431. URL: <https://doi.org/10.2307/1879431>.
- [2] Xiaoxuan Zhu и др. «VCEval: Rethinking What is a Good Educational Video and How to Automatically Evaluate It». В: (2025). arXiv: 2407.12005. URL: <https://arxiv.org/abs/2407.12005>.
- [3] Jing Shi и др. «Investigating Correlations of Automatically Extracted Multimodal Features and Lecture Video Quality». В: *Proceedings of the 1st International Workshop on Search as Learning with Multimedia Information (SALMM '19)*. ACM, 2019, с. 11—19. DOI: 10.1145/3347451.3356731. URL: <https://doi.org/10.1145/3347451.3356731>.
- [4] Yueran Pan и др. «A Multimodal Framework for Automated Teaching Quality Assessment of One-to-many Online Instruction Videos». В: *Proceedings of the 26th International Conference on Pattern Recognition (ICPR)*. IEEE, 2022, с. 1777—1783. URL: <https://ieeexplore.ieee.org/document/9956185>.
- [5] Google Developers. *Building with Gemini 2.0: Video Understanding*. 2024. URL: <https://www.youtube.com/watch?v=Mot-JEU26GQ> (дата обр. 23.05.2026).
- [6] Jay Peters. *Google is Testing AI Chatbot Search for YouTube*. 2026. URL: <https://www.theverge.com/streaming/919441/google-ask-youtube-ai-chatbot-search> (дата обр. 23.05.2026).
- [7] The Keyword. *YouTube Tests “Ask YouTube” AI Search Experience*. 2026. URL: <https://www.thekeyword.co/news/ask-youtube-ai-search> (дата обр. 23.05.2026).
- [8] Google Developers. *Video Understanding*. 2026. URL: <https://ai.google.dev/gemini-api/docs/interactions/video-understanding> (дата обр. 23.05.2026).

- [9] StudyFetch. *StudyFetch Documentation: Your Complete Guide to Mastering StudyFetch's AI-Powered Learning Tools*. 2024. URL: <https://www.studyfetch.com/> (дата обр. 23.05.2026).
- [10] Laxu AI Editorial Team. *Laxu AI vs Quizlet vs Anki vs StudyFetch vs Knowt: Best Flashcard App in 2026?* 14 янв. 2026. URL: <https://laxuai.com/blog/laxu-ai-vs-quizlet-vs-anki-comparison> (дата обр. 23.05.2026).
- [11] ITU-T. *Perceptual Evaluation of Speech Quality (PESQ): An Objective Method for End-to-End Speech Quality Assessment of Narrow-Band Telephone Networks and Speech Codecs*. P.862. International Telecommunication Union. 2001. URL: <https://www.itu.int/rec/T-REC-P.862> (дата обр. 23.05.2026).
- [12] Chandan K. A. Reddy, Vishak Gopal и Ross Cutler. «DNSMOS P.835: A Non-Intrusive Perceptual Objective Speech Quality Metric to Evaluate Noise Suppressors». В: *2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2022, с. 886—890. DOI: 10.1109/ICASSP43922.2022.9746108. arXiv: 2110.01763. URL: <https://arxiv.org/abs/2110.01763>.
- [13] Paul Boersma. «Praat, a System for Doing Phonetics by Computer». В: *Glott International* 5.9/10 (2001), с. 341—345. URL: https://www.fon.hum.uva.nl/praat/manual/FAQ/_How_to_cite_Praat.html (дата обр. 23.05.2026).
- [14] Johannes Wagner и др. «Dawn of the Transformer Era in Speech Emotion Recognition: Closing the Valence Gap». В: (2022). arXiv: 2203.07378. URL: <https://arxiv.org/abs/2203.07378>.
- [15] Zhou Wang и др. «Image Quality Assessment: From Error Visibility to Structural Similarity». В: *IEEE Transactions on Image Processing* 13.4 (2004), с. 600—612. DOI: 10.1109/TIP.2003.819861.
- [16] Zhi Li и др. *Toward a Practical Perceptual Video Quality Metric*. 6 июня 2016. URL: <https://techblog.netflix.com/2016/06/toward-practical-perceptual-video.html> (дата обр. 23.05.2026).

- [17] Anish Mittal, Anush Krishna Moorthy и Alan Conrad Bovik. «No-Reference Image Quality Assessment in the Spatial Domain». В: *IEEE Transactions on Image Processing* 21.12 (2012), с. 4695—4708. DOI: 10.1109/TIP.2012.2214050. URL: <https://doi.org/10.1109/TIP.2012.2214050>.
- [18] Haoning Wu и др. «Exploring Video Quality Assessment on User Generated Contents from Aesthetic and Technical Perspectives». В: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023. arXiv: 2211.04894. URL: <https://arxiv.org/abs/2211.04894>.
- [19] Camillo Lugaresi и др. «MediaPipe: A Framework for Building Perception Pipelines». В: (2019). arXiv: 1906.08172. URL: <https://arxiv.org/abs/1906.08172>.
- [20] Brandon Castellano. *PySceneDetect: Python-Based Video Scene Cut/Transition Detection Program and Library*. 2020. URL: <https://github.com/BreakthroughPySceneDetect> (дата обр. 23.05.2026).
- [21] Marti A. Hearst. «TextTiling: Segmenting Text into Multi-Paragraph Subtopic Passages». В: *Computational Linguistics* 23.1 (1997), с. 33—64. URL: <https://aclanthology.org/J97-1003/> (дата обр. 23.05.2026).
- [22] Lucas Ventura и др. «Chapter-Llama: Efficient Chaptering in Hour-Long Videos with LLMs». В: (2025). arXiv: 2504.00072. URL: <https://arxiv.org/abs/2504.00072>.
- [23] John Sweller. «Cognitive Load During Problem Solving: Effects on Learning». В: *Cognitive Science* 12.2 (1988), с. 257—285. DOI: 10.1207/s15516709cog12024.
- [24] Richard E. Mayer. *Multimedia Learning*. 2-е изд. New York: Cambridge University Press, 2009.
- [25] Richard J. Riding. «On the Nature of Cognitive Style». В: *Educational Psychology* 17.1–2 (1997), с. 29—49. DOI: 10.1080/0144341970170102.
- [26] Harold Pashler и др. «Learning Styles: Concepts and Evidence». В: *Psychological Science in the Public Interest* 9.3 (2008), с. 105—119. DOI: 10.1111/j.1539-6053.2009.01038.x.

- [27] Carl Gustav Jung. *Psychologische Typen*. Russian translation: *Психологические типы*, 1995. Zürich: Rascher Verlag, 1921. URL: https://archive.org/details/Psychologische_Typen (дата обр. 23.05.2026).
- [28] Isabel Briggs Myers и др. *MBTI Manual: A Guide to the Development and Use of the Myers-Briggs Type Indicator*. 3-е изд. Palo Alto, CA: Consulting Psychologists Press, 1998. ISBN: 0891061304.
- [29] Paul T. Costa и Robert R. McCrae. *Revised NEO Personality Inventory (NEO-PI-R) and NEO Five-Factor Inventory (NEO-FFI) Professional Manual*. Odessa, FL: Psychological Assessment Resources, 1992.
- [30] David J. Pittenger. «Measuring the MBTI... and Coming Up Short». В: *Journal of Career Planning and Employment* 54.1 (1993), с. 48—52.
- [31] Alec Radford и др. «Robust Speech Recognition via Large-Scale Weak Supervision». В: (2022). arXiv: 2212.04356. URL: <https://arxiv.org/abs/2212.04356>.
- [32] OpenAI. *Whisper large-v3-turbo*. 2024. URL: <https://huggingface.co/openai/whisper-large-v3-turbo>.
- [33] Sanchit Gandhi, Patrick von Platen и Alexander M. Rush. «Distil-Whisper: Robust Knowledge Distillation via Large-Scale Pseudo Labelling». В: (2023). arXiv: 2311.00430. URL: <https://arxiv.org/abs/2311.00430>.
- [34] SYSTRAN. *faster-whisper: Faster Whisper transcription with CTranslate2*. 2022. URL: <https://github.com/SYSTRAN/faster-whisper>.
- [35] Michael Chinen и др. «ViSQOL v3: An Open Source Production Ready Objective Speech and Audio Metric». В: *2020 Twelfth International Conference on Quality of Multimedia Experience (QoMEX)*. IEEE, 2020, с. 1—6. DOI: 10.1109/QoMEX48832.2020.9123150. arXiv: 2004.09584. URL: <https://arxiv.org/abs/2004.09584>.
- [36] Silero Team. *Silero VAD: Pre-Trained Enterprise-Grade Voice Activity Detector*. 2021. URL: <https://github.com/snakers4/silero-vad> (дата обр. 23.05.2026).

- [37] International Telecommunication Union. *Recommendation ITU-R BS.1770: Algorithms to measure audio programme loudness and true-peak audio level*. 2023. URL: <https://www.itu.int/rec/R-REC-BS.1770> (дата обр. 27.05.2026).
- [38] Christian J. Steinmetz. *pyloudnorm: A simple yet flexible loudness meter in Python*. 2018. URL: <https://github.com/csteinmetz1/pyloudnorm> (дата обр. 27.05.2026).
- [39] J. L. Pech-Pacheco и др. «Diatom Autofocusing in Brightfield Microscopy: A Comparative Study». В: *Proceedings of the 15th International Conference on Pattern Recognition (ICPR)*. Т. 3. IEEE, 2000, с. 314—317. DOI: 10.1109/ICPR.2000.903548.
- [40] Georg Martius. *vid.stab: Video Stabilization Library*. 2013. URL: <https://github.com/georgmartius/vid.stab> (дата обр. 27.05.2026).
- [41] Ao Wang и др. «YOLOE: Real-Time Seeing Anything». В: (2025). arXiv: 2503.07465. URL: <https://arxiv.org/abs/2503.07465>.
- [42] DeepSeek-AI. *DeepSeek-V4: Towards Highly Efficient Million-Token Context Intelligence*. Тех. отч. DeepSeek-AI, 2026. URL: <https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro> (дата обр. 23.05.2026).
- [43] Lorin W. Anderson и David R. Krathwohl. *A Taxonomy for Learning, Teaching, and Assessing: A Revision of Bloom's Educational Objectives*. Longman, 2001.